


폭과 네트워크를 결합한 분할 연합학습

시스템의 문제 정의와 모델링부터 KOREN 실험, Jetson 측정, LoRA 연합학습까지 연결한다.

폭과 네트워크를 하나의 학습 완료 목표로 연결

기기 계산량과 전송 자원은 서로 다른 제어 변수이며 같은 배치의 완료 시간에 함께 작용한다



관측 → 시간 예측 → 경로·폭 계획 → 전송·학습 → 다시 관측

시스템 개념도 | 폭 고정 경로 실험은 효과 분리를 위한 대조군 | 기존 결합 정책과 함께 유지

핵심 주장

AwareNet은 기기의 계산 부담을 조절하는 모델 폭과 통신 자원을 조절하는 경유 경로를 공통 완료 시간 모형으로 연결한다. 네트워크 개선으로 학습 폭을 보존할 여지를 만들고, 남는 기기 계산 부담을 폭 제어로 조절하는 시스템을 구현했다.

기존 KOREN 결합 실험, 실물 Jetson의 계산 프로파일, VM과 HPC 사이의 실제 LoRA 분할 연합학습이 서로 다른 측면의 근거를 제공한다. 각 실험의 장비·조건·측정 범위를 연결해 설명하는 것이 이번 결과의 강점이다.

확정 범위 기존 결합 시스템과 하드웨어 기반 검증을 중심에 둔다. 폭 고정 경로 정책은 네트워크 효과를 분리하는 대조군으로, 기울기 반환 순서는 후속 연구 후보로 배치한다.

서로 다른 변수를 공통 목적에 연결

두 제어가 상호 보완되는 이유는 왕복 바이트와 실효 전송률이 같은 시간 항에 함께 들어가기 때문이다.

상호 보완 관계를 담은 시간 모형

기존 CNN 폭 정책의 배치당 근사식 | 직렬 계산·전송 기준 | LoRA rank에는 별도 프로파일 필요

$$t_i(w_i, S) = c_i w_i^{\gamma_i} + 8 b_i w_i / R_i(S) + \epsilon_i$$

폭에 따른 계산 시간

폭과 경로가 함께 정하는 전송 시간

$$J(w, S) = \max_i [B \cdot t_i(w_i, S) + \delta_i] + (\lambda/N) \sum_i (1 - w_i)$$

w_i : 정규화된 모델 폭 S : 모든 기기의 경로 배정 $R_i(S)$: 공유 제약 아래 전송률

c_i, b_i : 전폭 계산 시간·왕복 바이트 γ_i : 계산 스케일 지수 ϵ_i : 관측 잔차

B : 라운드의 배치 수 δ_i : 경로 전환 비용 λ : 평균 폭 손실의 시간 단위 가격

경로 개선 → 같은 폭의 전송 시간 감소 → 필요한 폭 축소량 감소

구현은 단계적 탐욕 계획과 히스테리시스 · 전역 최적해나 정확도 보장으로 해석하지 않는다

근거: `sfl/plan.py round_times · _t_one · opt_widths` | 폭 손실은 정확도 손실의 측정값이 아님

계산과 통신의 결합 폭 w 를 줄이면 계산 항 $c \cdot w^{\gamma}$ 가 작아지고, 기존 CNN 근사에서는 전송 바이트 $b \cdot w$ 도 작아진다. 경로 배정 S 는 공유 링크를 사용하는 모든 기기의 전송률 $R(S)$ 에 영향을 준다. 같은 목표 시간에서 좋은 경로가 확보되면 폭을 덜 줄이고도 완료할 수 있다.

폭 보존의 가격 λ 는 평균 폭 손실 한 단위를 시간으로 환산하는 설정값이다. $\sum(1-w)/N$ 은 실제 정확도 손실을 측정 한 함수가 아니다. 폭 하한, 허용 종점, 공유 용량, 라운드별 이동 상한을 함께 적용한다.


식은 기존 `plan.py`를 설명하는 근사 모형이다. 구현은 경로 단계와 폭 단계의 탐욕적 개선 및 히스테리시스이며, 전역 공동 최적해를 증명한 것은 아니다. 잔차·효율 보정은 코드 경로에 따라 선택하며, LoRA rank에 CNN의 $b \cdot w$ 관계를 그대로 적용하지 않는다.

실제 하드웨어와 실회선을 활용한 검증

그림 속 장비의 역할과 물리 장비 수를 실험별로 구분한다.

실제 장비와 실제 회선에서 이어진 검증

KOREN 실망 학습과 Jetson 보드 측정은 각자의 원시 기록을 가진 별도 실험이다



KOREN VM 2대 ≠ 물리 클라이언트 32대 | Jetson 1대의 모드별 표본 ≠ 다수 보드 동시 학습



보관된 실제 Jetson 장비 사진

보드 전력 모드별 30개, 총 90개 스텝을 측정했다. 전체 스텝 중앙값은 MAXN 554.1ms, 25W 608.9ms, 15W 903.7ms다.

이 보드 프로파일과 VM의 분할 연합학습은 서로 다른 실행이다.


KOREN 결합 리그에는 HPC의 논리 기기가 VM을 경유해 돌아오는 구성과 VM에 기기를 배치한 구성이 모두 있다. LoRA 연합 실험은 VM1에 c0-c1, VM2에 c2를 두고 HPC 서버와 통신했다. 8개 또는 32개 논리 참여자를 물리 단말 수로 환산하지 않는다.

결합 시스템의 효과를 실망에서 관찰

원 로그의 조건별 시드 평균을 재계산했다. 학습량과 경로가 함께 바뀐 시스템 비교다.

KOREN 결합 시스템의 기존 실험 결과

32개 논리 참여자 · 조건별 3시드 · 첫 4라운드 제외 · 시드 평균의 평균



기존 결합 시스템 비교: 폭·출구·경로가 함께 변경 | 동일 정확도 효과 또는 새 network 정책 성능이 아님

정상·트래픽 몰림·연산 느림·용량 변동에서 평균 라운드 시간은 기준선보다 약 24.6~42.6% 감소했다. 실제 회선, 가상머신의 CPU·메모리, tc 제한 및 교란을 포함한 실행 기록을 가진다는 점에서 순수 수치 모형만의 검토보다 구현 근거가 구체적이다.

축소 실행은 CPU·메모리 제약 때문에 필요한 실험 방식이었다. 32대 조건과 8대 실행은 각 로그의 논리 참여자 수·회선 상한·노이즈 조건으로 설명한다. 부하 비율을 맞춘 설계만으로 계산·학습·확률적 동작까지 동등해지는 것은 아니다.


여기서는 폭, 출구 수, 경로가 함께 바뀌었다. 따라서 감소율을 경로만의 효과나 같은 정확도까지의 시간 단축으로 표시하지 않는다. 새 network 정책 및 LoRA 실행의 성능과도 합산하지 않는다.

관측과 계획을 실제 전송에 연결

학습 변수와 네트워크 변수를 계층으로 구분하되 공통 관측과 시간 목표로 결합한다.

모델링에서 실제 실행까지 연결되는 구조

경로 선택의 단위는 보유 VM의 경유 중점 | 기기의 접속망 전체를 제어한다는 가정을 두지 않는다



기기 권한 일반 소켓·허용 중점 선택

운영팀 권한

보유 VM·브리지 범위

OS-Ken 집행기는 별도 프로토타입 | 앱 완료 보고는 물리 경로 증명·OVS 설치 ACK·기기 인증과 구분

분할 전송은 activation과 gradient 양방향에 적용하며, 수신 측은 조각 위치·크기·중복 충돌을 확인해 완성본을 학습 단계에 전달한다. 제어기가 요구한 중점과 앱의 완료 보고를 대조해 다음 판단에 사용한다.

기기에는 일반 소켓 권한을 요구하고, 운영팀이 가진 VM과 브리지에서만 정책을 집행하는 구조다. KOREN 코어 라우터나 가입자 접속망에 대한 관리자 권한을 가정하지 않는다. 현재 엣지 변경은 경유 중점 변경이며 학습 상태의 서버 간 이동은 포함하지 않는다.


OS-Ken/OVS 집행기는 후속 프로토타입이다. 실제 스위치 설치 확인과 자동 계획 연동, 기기 인증·암호화는 남아 있다. 관련 로컬 경로·소켓·기울기·재현 테스트 53개는 통과했지만 현장 SDN 검증을 대신하지 않는다.

실제 분할 연합학습까지 이어진 구현

모델 분할, 양방향 역전파, 기기별 학습, 라운드 집계를 실회선에서 실행했다.

LoRA로 확인한 모델 분할과 연합 집계

Qwen2.5 0.5B · 앞 2층 분할 · LoRA rank 16 · 3개 논리 기기 · 16라운드



실제 구현: activation과 labels 전송, gradient 반환 | 본 그림은 앞·뒷단 모두 평균하는 v1 대조 실행

서로 다른 사실을 가진 B1·B2·B3 도메인을 세 논리 기기에 나눠 학습했다. 기기는 모델 앞부분을 실행하고 HPC 서버가 뒷부분의 손실과 gradient를 계산한다. 라운드마다 앞단 어댑터를 평균하는 실행과, 기기별 뒷단 상태까지 별도로 학습한 후 앞·뒷단 모두 평균하는 대조 실행을 보존했다.

후자의 서버 로그에는 16개 라운드가 있으며 라운드 시간 합은 588.8초다. 이는 전체 배포·준비 시간과 구분한다. 각 라운드의 평균 전 뒷단 상태 거리가 0보다 커 기기별 상태 갱신이 실제로 이루어진 기록도 남아 있다.

정확한 명칭은 **모델의 층 분할을 이용한 분할 연합학습**이다. 동일 샘플의 서로 다른 특징을 여러 기관이 가진 수직 연합학습 VFL과는 데이터 분할 방식이 다르다. LoRA에서는 학습 가능한 어댑터를 줄여 학습·집계 부담을 낮추지만 절단면 activation의 크기가 rank에 비례해 줄지는 않는다.

단독 학습을 넘어서는 도메인 결합을 확인

18개 평가 문항의 원문 판정과 저장된 엄격 판정을 적용했다.

분산 도메인의 학습 결과가 연합 모델에 반영

엄격 판정 적용 · heldout 문형 18개 · B1 8개 / B2 3개 / B3 7개 · 단일 소규모 실행

베이스		0/18	정답 수
	B1 0/8 · B2 0/3 · B3 0/7		
단독 B1		6/18	33.3%
	B1 6/8 · B2 0/3 · B3 0/7		
연합 뒷단 공유		12/18	66.7%
	B1 6/8 · B2 2/3 · B3 4/7		
연합 앞·뒷단 평균		12/18	66.7%
	B1 4/8 · B2 2/3 · B3 6/7		

문형을 바꾼 알려진 사실 평가 | 새 지식 일반화·대규모 정확도·폭·경로 결합 성능을 입증하는 수치는 아님

단독 B1 모델은 B1에서 6/8, B2·B3에서 0개를 맞혔다. 연합 모델은 다른 기기가 가진 B2·B3 사실에도 응답했다. 앞·뒷단 모두 평균한 대조군은 B1 4/8, B2 2/3, B3 6/7로 총 12/18이었다. 이는 실제 연합 집계기 작동한 소규모 기능 검증이다.

도메인 간 간섭도 관찰됐다. 앞·뒷단 평균 대조군의 B1 점수는 단독보다 낮다. 평가 대상은 학습 사실의 다른 문형 이므로 광범위한 일반화 능력으로 해석하지 않는다. 문답에 등장하는 통신 숫자는 학습 코퍼스의 내용이며 이번 KOREN 회선 측정값으로 재인용하지 않는다.


activation과 토큰 labels가 서버로 전달된다. 한 기기에만 넣은 가짜 비밀을 묻는 카나리아 문항 3개가 연합 모델에서도 노출됐다. 따라서 데이터 비공개·프라이버시 보장을 성과로 주장하지 않는다.

기기에서 감당할 수 있는 모델 범위를 넓힘

메모리 프로파일과 실제 분할 학습 로그를 각각 확인한다.

모델 분할로 기기에 필요한 메모리를 낮춤

KOREN VM CPU 프로파일 · batch 4 / sequence 256 / rank 16 / 앞 2층 · peak RSS



front 단독 프로파일이며 서버 메모리·통신·전체 학습 시간을 포함하지 않음 | GB = 기록 MB / 1000

VM의 7B 로컬 LoRA 프로파일은 OOM을 기록했고, 앞 2층만 보유한 front 프로파일은 약 6.44GB RSS로 실행됐다. 별도의 VM↔HPC 7B 실제 분할 학습에서는 10스텝을 수행했으며 기기 RSS는 약 7.94GB였다. 두 메모리 수치는 서로 다른 실행 조건이다.

7B 실제 분할 학습의 처음 2스텝 평균 손실은 2.01, 마지막 2스텝 평균은 0.55였다. 짧은 실행에서 역전파와 갱신이 성립한 증거이며, 수렴·정확도 또는 기존 CNN 폭·경로 결합 최적화가 LoRA에 통합됐다는 증거는 아니다.

분할은 기기 부담 일부를 서버 계산과 통신으로 옮긴다. 이 때문에 기기 자원만 줄여 보는 평가로는 부족하며, 폭·분할·어댑터 크기와 실제 네트워크 비용을 함께 관측하는 시스템 관점이 필요하다.

설계의 변화와 각 검증 결과를 연결

새 기능을 늘리기보다 현재 구현과 증거가 지지하는 결론을 하나의 이야기로 묶었다.

문제 정의에서 검증까지 이어지는 논리

기기 자원과 전송 자원을 함께 모델링하고 각 실험이 뒷받침하는 주장으로 결론을 연결한다

01

기기 부하

폭·모델 분할로 조절

02

반복 왕복 전송

공유 병목·경유 선택

03

공통 완료 목표

시간·폭 대가의 모델링

■ 실제 회선·학습

KOREN 결합 실험
VM↔HPC LoRA 학습

■ 실제 장비 프로파일

Jetson 전력 모드별 시간
메모리·OOM 관측

■ 실측값 기반 재현

시간 모형·로컬 TCP
새 제어의 조건·반례

향후 과제: 실제 OVS 집행·동일 정확도까지의 시간·통합 LoRA 네트워크 제어 | 후속 후보의 성능은 미확정

초기 폭 조절에서 출발해 통신 병목을 함께 모델링했고, 실제 경유·양방향 분할 전송과 재조립으로 연결했다. 후속 network 정책은 폭을 고정해 경로 효과를 분리하도록 만들었다. 기울기 반환 순서의 연구는 어느 조건에서 계산과 전송이 겹칠 수 있는지 검토하는 보완 단계다.

Jetson과 KOREN의 기존 수치를 주입한 대표 조건에서 시간 모형은 9.97%, 로컬 TCP는 9.91% 단축을 보였다. 전체 스텝 중 이후 계산 비율을 0.5로 가정한 결과이며, 회선 계수 0.1배에서는 1.60%로 줄었다. 새 현장 학습 성능이나 실제 장비를 동시에 연결한 결과로 부르지 않는다.

추가 조각 재전송, 자동 공유 병목 탐지, 동적 분할 깊이는 후속 후보로 보존한다. 이번 확정 범위는 기존 결합 시스템, 실제 하드웨어의 실험 근거, LoRA 분할 연합학습 기능 검증이다.

제출에서 강조할 기여와 근거

코드·측정·평가 원문을 연결한 최종 주장 범위

제출용 결론

AwareNet은 기기 부하를 조절하는 모델 폭과 통신 자원을 조절하는 네트워크 경로를 공통 시간 모형으로 연결한 분할 연합학습 시스템이다. 실제 KOREN 구간에서 기존 결합 시스템을 실행하고, Jetson 보드의 계산 자원 특성을 측정했으며, KOREN VM과 HPC 사이에서는 LoRA 기반 모델 분할과 연합 집계기 작동함을 확인했다. 이 성과는 모델링, 전송 구현, 실제 장비 측정, 학습 기능 검증을 연결한 시스템 구현의 근거다.

현재 증거가 지지하는 범위

- 결합 모형과 실행 구조: plan.py, network_control.py, mpsend.py, chunker.py 및 관련 검사.
- 기존 KOREN 라운드 단축: 결합 시스템 비교. 동일 정확도 또는 순수 경로 효과는 별도 검증 필요.
- LoRA 분할 연합학습: VM CPU와 HPC 서버, 3개 논리 기기, 16라운드 및 18문항 평가.
- 실물 Jetson: 모드별 30스텝 계산 프로파일. KOREN LoRA 연합 실행과 별도.
- 남은 검증: 실제 OVS 집계와 신원 인증, 동일 정확도까지의 시간, LoRA와 동적 네트워크 제어의 통합.

근거 문서와 원자료

- [1] docs/02_실험/데이터_기록_2026-09-07.md · KOREN 및 9/13 LoRA 실행 기록
- [2] docs/02_실험/실험_연합분할LoRA_문답증명_사전등록_2026-09-13.md
- [3] out/fed_split/eval_0913v1.json + strict_0913v1.json · 문답과 엄격 판정
- [4] out/fed_split/server_fed3v1_0913.jsonl · 16라운드 원시 로그
- [5] out/scale_lora/cost_llm_0913_vm.jsonl · 모델 크기별 자원 프로파일
- [6] configs/measurements/koren_jetson_2026-09-23.json · Jetson·전송 원시 입력
- [7] configs/measurements/final_report_evidence_2026-09-26.json · 이번 재계산과 출처 해시
- [8] LoRA arxiv.org/abs/2106.09685 · SplitLoRA arxiv.org/abs/2407.00952
- [9] VFL 용어 arxiv.org/abs/2211.12814 · 특징 분할과 모델 층 분할의 구분