

K-디지털 챌린지 : 넷 챌린지 캠프 시즌13

최종결과보고서

분할 연합학습을 위한
모델과 네트워크의 적응형 스케줄링

AwareNet

본 보고서를 K-디지털 챌린지 : 넷 챌린지 캠프 시즌13의
최종결과보고서로 제출합니다.

2026년 9월 30일

참여 구성원
성시준 · 석태경
충남대학교 전파정보통신공학과

한국지능정보사회진흥원장 귀하

안 내 사 항

1. 본 연구보고서는 한국지능정보사회진흥원의 출연금으로 수행한 K-디지털 챌린지 : 넷 챌린지 캠프 시즌13의 연구망 활용 연구과제 결과입니다.
2. 본 연구보고서의 내용을 발표할 때에는 반드시 한국지능정보사회진흥원 K-디지털 챌린지 : 넷 챌린지 캠프 시즌13의 연구망 활용 연구과제 결과임을 밝혀야 합니다.

요 약 문

1. 제 목

AwareNet 분할 연합학습을 위한 모델과 네트워크의 적응형 스케줄링

2. 아이디어 개발의 목적 및 필요성

연합학습은 각 기관에 데이터를 둔 채 학습 결과를 모아 하나의 모델을 개선하는 방법이다. 분할 연합학습은 계산을 서버와 나누어 클라이언트의 부담을 줄인다. 다만 학습 중간 결과를 자주 주고받아 통신이 느려지면 전체 학습도 지연된다. 본 프로젝트는 지연 원인에 맞춰 모델 크기와 전송 경로를 함께 조절한다.

3. 아이디어 개발의 내용 및 범위

AwareNet은 모델 폭, 중계 경로와 텐서 분할 전송을 함께 조절한다. 텐서를 조각으로 나누어 연결별 예상 전송률에 맞춰 배분하고, 중계 배정으로 줄일 수 있는 지연을 먼저 평가한다. 남은 지연에는 모델 축소의 시간 이득과 비용을 비교한다. 용량 변화 직후에는 폭을 유지한다. CNN의 시간·정확도와 LoRA의 분할 학습·집계·전송을 평가했다.

4. 개 발 결 과

KOREN에서 동시 전송이 늘수록 지연이 커지는 현상을 확인하고, CPU와 메모리 한도에 맞춰 실험 규모를 줄였다. 32개 논리 클라이언트를 3개 시드로 평가한 결과, 트래픽 물림과 연산 지연에서 라운드 시간이 각각 42.6%, 40.3% 짧아졌다.

별도의 8클라이언트·200라운드 평가에서는 채널 비율을 유지하면서 시간이 20.7% 줄었고, 정확도 차이는 약 -0.29% 였다. 두 비교 모두 기준 방식의 연결 1개와 AwareNet의 연결 2개를 포함한 전체 구성의 결과다.

5. 기 대 효 과

병원이나 제조기관에서 자원이 다른 클라이언트도 공동 학습에 참여하도록 돕는다. 각 기관의 대기 시간을 줄여 공동 모델을 꾸준히 개선하는 것이 기대 효과다. 실제 도입에는 기관별 사용 권한과 통신 보안을 함께 마련해야 한다.

목 차

I. 서 론	6
1. 개발 목적 및 필요성	6
2. 특징	7
II. 아이디어 개발 추진 내용과 범위	8
1. 개발 목표 및 추진 내용	8
2. 단계별 세부 구현 계획	11
III. 아이디어 개발 진행 내용 및 결과	15
1. 개발 수행 현황 및 최종 결과물	15
2. KOREN 연동 및 활용 결과	16
3. 멘토 의견에 따른 개선사항	19
4. 결과물의 통합 및 시험/검증 결과	20
IV. 결 론	24
1. 개발 최종 결과물	24
2. 기술 구현에 따른 기대 효과	24
V. 참고문헌	25

그림 목차

- 그림 1. 스케줄러와 KOREN 실험 구성 8
- 그림 2. 라운드 단위 제어 파이프라인과 피드백 11
- 그림 3. 지속 TCP 연결의 텐서 분할·재조립 13
- 그림 4. KOREN 중단 간 경로의 동시 전송 규모별 완료 시간 17
- 그림 5. 조건별 평균 라운드 완료 시간 18
- 그림 6. 여러 기관의 전역 모델 공동 개선 활용 예시 24

표 목차

- 표 1. 선행연구의 제어 대상과 AwareNet의 설계 초점 7
- 표 2. 공통 시스템에 연결한 두 학습 구현 9
- 표 3. 제어 단계별 입력과 출력 11
- 표 4. 구현된 응용 메시지 프레임 13
- 표 5. Jetson의 전력 모드별 스텝 시간 중앙값 15
- 표 6. 제어 응답 및 장기 학습의 실행 조건 18
- 표 7. 멘토 의견과 반영 내용 19
- 표 8. 축소 가중치에 따른 시간과 정확도 20
- 표 9. Fashion-MNIST 추가 학습의 정확도와 텐서 크기 20
- 표 10. 최종 시연의 실행 조건과 결과 21
- 표 11. 모델과 학습 기법별 실험 총괄 22
- 표 12. 기능 활성화에 따른 시간과 정확도 23

I. 서론

1. 개발 목적 및 필요성

의료·제조 분야에서는 개인정보 보호와 기관별 관리 정책 때문에 데이터를 한곳에 모으기 어렵다. 연합학습(Federated Learning, FL)은 데이터를 각 클라이언트에 둔 채 학습 결과를 모아 공동 모델을 만든다.[1] 다만 연산 능력이나 메모리가 부족한 클라이언트는 전체 모델을 학습하기 어렵다.

분할 연합학습(Split Federated Learning, SFL)은 모델의 앞부분을 클라이언트가, 뒷부분을 서버가 학습해 계산 부담을 나눈다.[2] 이때 매 배치마다 중간 계산 결과인 활성화값과 모델 갱신에 필요한 기울기를 주고받는다. 따라서 클라이언트의 계산 속도와 네트워크 상태가 모두 학습 시간에 영향을 준다.

본 프로젝트는 모든 클라이언트가 한 라운드를 마친 뒤 결과를 모으는 동기식 구조를 사용한다. 이 구조에서는 가장 늦게 끝나는 클라이언트가 전체 진행을 늦춘다.

모델의 일부만 사용하는 서브모델 학습은 계산량과 전송량을 줄이는 방법이다.[3,4] CNN에서는 사용하는 채널 수, 즉 모델 폭을 줄인다. 그러나 학습하는 모델이 작아지고 가중치의 갱신 기회도 달라져 정확도가 낮아질 수 있다.

통신 혼잡이 원인이라면 경로를 바꾸어 모델 크기를 유지할 여지가 있다. 반면 계산이 느리거나 모든 경로가 같은 포화 회선을 지나면 경로 변경만으로 지연을 줄이기 어렵다.

AwareNet은 모델 폭, 중계 경로와 텐서 분할 전송을 함께 선택한다. 폭은 계산량과 전송량을, 중계 배정은 전송 경합을 조절한다. 텐서를 작은 조각으로 나누면 연결별 처리 능력에 맞춰 부하를 배분할 수 있다. 이 전송 구성의 예상 완료 시간을 바탕으로, 모델 축소의 시간 이득이 충분할 때 폭을 줄인다.

2. 특징(동일·유사 아이디어에 대한 차별성·독창성·혁신성)

같은 통신 지연이라도 다른 경로로 분산할 수 있는 경우와 공유 회선이 이미 포화된 경우는 다르게 대응해야 한다. AwareNet은 경로 변경으로 줄일 수 있는 시간을 먼저 계산하고, 그 결과를 모델 크기 선택에 반영한다.

가. 차별성: 모델 선택에 네트워크 경로를 결합

FjORD·FedRolex는 이질적인 클라이언트의 서브모델 학습을, AdaptSFL·SuperSFL은 자원 적응형 분할 연합학습을 다룬다.[3-6] 라우팅과 모델 축소의 결합을 다룬 후속 연구도 있다.[16] AwareNet은 배치마다 텐서를 교환하는 SFL에서 허용된 중계와 분할 전송을 평가한 뒤 모델 축소 여부를 결정하는 실행 구조에 초점을 둔다.

표 1. 선행연구의 제어 대상과 AwareNet의 설계 초점

접근	주요 제어 대상	설계 초점
FjORD FedRolex	서브모델 크기·추출	성능이 다른 모델의 학습
AdaptSFL SuperSFL	분할·집계 또는 서브네트워크	통신·연산 자원 적응
AwareNet	폭·중계·전송 비율	경로 개선 후 축소 판단

나. 독창성: 공유 회선과 설정 변경의 영향 반영

여러 연결이 같은 회선을 사용하면 각 연결이 쓸 수 있는 속도도 줄어든다. AwareNet은 중계의 공유 용량과 클라이언트의 접속 상한을 함께 계산해, 경로 변경과 폭 축소의 효과를 초 단위로 비교한다.

폭은 경로 변경을 마친 상태를 기준으로 선택한다. 또한 관측한 용량이 바뀐 라운드에는 폭을 유지한다. 경로를 옮기는 중의 일시적인 지연 때문에 모델을 지나치게 줄이지 않기 위해서다.

다. 실용성: 모듈 분리와 실제 환경의 검증

학습, 텐서 전송, 망 설정을 모듈로 나누어 사용 권한에 맞게 배치했다. KOREN에서 종단 간 전송과 CNN 학습을 실행하고, 별도 장기 학습으로 시간·정확도를 비교했다. Jetson에서는 연산·전력을 측정했다. LoRA는 분할 학습과 집계에 더해 중계 배정에 따른 어댑터 전송 시간도 확인했다.

II. 아이디어 개발 추진 내용과 범위

1. 개발 목표 및 추진 내용

가. 개발 목표

목표는 성능이 다른 클라이언트가 함께 학습할 때 모델 품질을 확인하면서 라운드 완료 시간을 줄이는 것이다. 가장 늦은 클라이언트의 예상 시간과 모델 축소 비용을 합친 값 J로 설정을 비교한다. 사용할 수 있는 중계와 회선 용량 안에서 설정을 고르고, 시간과 정확도의 관계는 장기 학습으로 평가한다.

나. 세부 추진 내용 및 범위

AwareNet 전체 구조




그림 1. 스케줄러와 KOREN 실험 구성

시스템은 관측, 계획, 실행을 반복한다. 먼저 연산 시간과 전송 기록을 모은다. 이 기록으로 모델 크기와 중계 경로를 선택하고 다음 라운드에 적용한다. 실행 결과를 다시 수집하므로 이후 선택에 실제 완료 시간을 반영할 수 있다.

여기서 경로 선택은 학습 데이터를 보낼 중계 서버와 연결을 고르는 응용 계층의 제어다. 클라이언트 프로그램이 중계를 선택하고 연결별 텐서 전송량을 배분한다. 관리 호스트의 회선 설정은 실험 조건을 재현하는 데 사용한다. 이를 통해 KOREN 내부의 스위치나 라우터 설정 권한 없이 종단 간 전송을 조절한다.

1) 모델 폭과 사용할 채널의 선택

CNN의 모델 폭은 한 계층에서 사용하는 채널 수다. 스케줄러는 전체 채널 중 사용할 비율을 정하고, 학습 모듈은 실제 사용할 채널을 고른다. 이 두 선택을 나누어 모델 크기 조절과 채널 선택 알고리즘을 각각 바꿀 수 있게 했다.

같은 채널만 반복해서 고르면 일부 가중치에 학습이 집중될 수 있다. FedRolex식 순환 선택은 라운드마다 채널 위치를 바꾸고, 학습 결과를 원래 가중치 위치에 맞춰 모은다.[4] 고정 선택과 순환 선택을 모두 구현했으며, 순환 선택과 집계는 별도 300라운드 실행으로 검증했다. CNN의 계층 수와 클라이언트·서버 분할 위치는 고정했다.

2) CNN과 LoRA의 적용 범위

CNN은 채널 수를 바꾸면 계산량과 중간 전송량이 함께 달라져 폭·경로 제어를 평가하기에 적합하다. 다른 알고리즘도 설정별 연산 시간, 전송량과 집계 방법을 제공하면 같은 구조에 연결할 수 있다. 전송 모듈은 특정 채널 선택 방법에 묶이지 않도록 설계했다.

표 2. 공통 시스템에 연결한 두 학습 구현

구분	CNN 서브모델 학습	LoRA 언어모델 학습
자원 조절 변수	채널 비율·선택 위치	추가 학습 행렬의 랭크
전송량과의 관계	채널 수에 따라 활성값·기울기 크기 변화	랭크는 어댑터 집계량에 영향 분할 활성값 차원은 유지
검증 목적	폭·경로 제어의 시간·정확도 별도 채널 순환 선택	고정 랭크의 분할 실행 메모리 사용·연합 집계

LoRA는 원래 가중치를 고정하고 작은 저랭크 행렬인 어댑터를 학습한다.[7,8] 분할 공동 학습과 별도의 중계 배정 실험은 랭크 16으로 실행했다. 후자는 어댑터 업로드 시간을 비교해 언어모델 학습에도 전송 제어를 적용할 기반을 확인했다. 동적 랭크와 경로의 결합 제어는 랭크별 비용 측정과 후속 통합이 필요하다.

3) 완료 시간의 예측과 설정 선택

한 배치의 시간 τ_i 는 클라이언트 연산 C_i , 활성화 전송 U_i , 서버 처리 S_i , 기울기 반환 D_i 의 합이다. 서버에서 기다리는 시간도 S_i 에 포함한다. 라운드당 배치 수를 B , 모델 배포·집계 시간을 T_0 라 하면 전체 시간은 가장 늦은 클라이언트를 기준으로 계산한다.[2,5]

$$\tau_i = C_i + U_i + S_i + D_i \quad (1)$$

$$T_{round} \approx T_0 + \max_i (B \cdot \tau_i) \quad (2)$$

식 (3)은 폭 비율 w_i 와 중계 배정 P 에서의 시간을 예상한다. c_i 와 b_i 는 전폭 모델의 배치당 연산 시간(초)과 왕복 전송량(바이트)이다. R_i 는 실제 사용할 수 있는 전송률(bit/s), o_i 는 고정 처리 시간과 예측 오차를 보정하는 값이다. γ_i 는 폭에 따라 연산 시간이 줄어드는 정도를 나타내며 기본값은 1.2다.

$$\hat{T}_i(w_i, P) = B [c_i w_i^{\gamma_i} + \frac{8 b_i w_i}{R_i(P)} + o_i] \quad (3)$$

R_i 는 중계 용량을 나눠 쓰는 연결 수와 클라이언트의 접속 상한을 반영한다. 접속 회선이 같으면 연결 속도의 합을 제한하고, 독립 회선이면 각 연결을 제한한다. 이 값으로 경로 변경과 모델 축소가 각각 시간을 얼마나 줄이는지 비교한다.

$$J(w, P) = \max_i \hat{T}_i + \frac{\lambda}{N} \sum_i (1 - w_i) \quad (4)$$

N 은 클라이언트 수다. λ (람다)는 모델 축소에 부여하는 비용의 크기를 정하는 설정값이다. 크게 잡으면 모델 폭을 더 유지하고, 작게 잡으면 시간 단축을 위해 더 적극적으로 줄인다. 이 비용을 예상 시간과 더해 비교하므로 λ 의 단위는 초다.

축소 전후 최대 시간 차이를 ΔT , 평균 채널 비율의 감소를 Δw 라 한다. 예상 시간 이득을 10% 낮춰 잡은 값($\eta=0.10$)이 축소 비용보다 클 때만 폭을 줄인다.

$$(1 - \eta) \Delta T > \lambda \Delta w \quad (5)$$

계산 예로, $\lambda=70$ 초에서 평균 채널 비율을 0.1 줄이면 축소 비용은 7초다. 10% 보정 후의 예상 시간 이득이 7초를 넘어야 이 축소를 선택한다. λ 는 사용자가 정하며, 정확도 영향은 실제 학습으로 확인한다.

경로는 시간 합계와 N 배의 최대 시간을 함께 평가해 고른다. 선택한 경로에서 폭을 비교할 때 식 (4)·(5)를 적용한다.

다. 참여구성원별 역할

- 성시준: 전체 설계·개발 총괄, 네트워크 제어, KOREN 구성·실측.
- 석태경: 분할 연합학습 파이프라인, 실험 설계·분석, 결과 시각화.

2. 단계별 세부 구현 계획

제어는 상태 측정, 설정 선택, 실행의 세 단계로 진행한다. 모델과 경로는 라운드 사이에 정하고, 배치 실행 중에는 정해진 설정으로 데이터를 보낸다. 전송 중인 데이터마다 설정을 다시 계산할 필요가 없도록 구성했다.




그림 2. 라운드 단위 제어 파이프라인과 피드백

가. 라운드별 제어 과정

표 3. 제어 단계별 입력과 출력

단계	입력	출력
상태 측정	사전 연산 시간 전송량·소요 시간	연산·전송 특성 중계 용량 추정값
설정 선택	측정값·현재 배정 허용 경로·용량 상한	다음 라운드의 폭 중계 배정·분할비
실행·결과 수집	선택한 설정 전역 모델의 파라미터	클라이언트별 모델·연결 라운드 결과·전송 기록

1) 연산 시간과 전송 상태 측정

① 최근 실행 기록으로 연산 시간과 경로 상태를 갱신한다. ② 공유 접속·중계 용량을 반영해 경로별 전송률을 계산한다. ③ 현재 폭에서 완료 시간을 줄이는 중계 배정을 찾는다. ④ 해당 배정에서 식 (4)·(5)로 폭 축소의 시간 이득과 λ 에 따른 비용을 비교한다.

⑤ 용량 변화 직후에는 폭을 유지하고, 그 외에는 선택한 폭을 적용한다. ⑥ 연결별 예상 전송률에 맞춰 텐서 조각을 배분한다. ⑦ 학습과 집계를 수행하고 결과를 다음 라운드에 반영한다. 연산 프로파일, 최근 3라운드의 용량 관측값과 예측 오차 보정으로 이 절차를 반복한다.[12]

2) 경로 선택 후 모델 폭 조절

먼저 현재 폭을 유지하면서 허용된 중계 조합을 비교한다. 점수 G 는 모든 클라이언트의 시간 합계와 가장 늦은 완료 시간을 함께 반영한다. 최대 시간에 N 을 곱해, 여러 클라이언트가 조금 빨라지더라도 가장 느린 클라이언트가 더 늦어지는 선택을 억제한다.

경로 평가에는 관측 시간과 예측 시간의 비율을 보정값으로 사용한다. 이후 폭 평가에는 식 (3)의 시간 오차 보정값을 사용한다.

$$G(P | w) = \sum_i \hat{T}_i(w, P) + N \max_i \hat{T}_i(w, P) \quad (6)$$

다음은 경로 이동을 모두 마쳤다고 가정한 배정에서 폭을 고르는 단계다. 가장 늦은 클라이언트와 지연이 비슷한 집단의 폭을 한 단계 줄여 시간 이득 ΔT 를 구한다. 식 (5)를 만족할 때 축소를 채택한다. 경로 이동 중에 생기는 일시적인 지연으로 모델 크기를 결정하지 않기 위해서다.

탐색량은 후보 수로 제한한다. 중계 K 개를 두 연결에 배정할 때 클라이언트별 후보 C 는 최대 K^2 개다. 전체 조합 $Q = \prod_i C_i$ 가 20,000 이하이면 모두 비교한다. 그보다 많으면 전송량이 큰 클라이언트부터 배정하는 탐욕 방식으로 $O(NC)$ 회 평가한다.

라운드당 M 개의 경로 이동을 고르는 데는 $O(MNC)$ 회 평가한다. 폭 후보가 L 단계일 때 축소 반복은 최대 $N(L-1)$ 회이고, 반복마다 최대 N 개 후보를 비교한다. 각 평가에는 공유 용량 계산이 추가된다.

3) 설정 적용과 결과 수집

서버는 RSTART 메시지로 라운드 번호, 폭, 모델 가중치, 중계 주소와 전송 비율을 각 클라이언트에 보낸다. 클라이언트는 해당 서브모델을 만들고 기존 연결을 재사용한다. 별도로 검증한 순환 선택 모듈은 채널 위치를 바꾸어 학습하고 원래 위치에 맞춰 결과를 모은다. 학습 모듈이 바뀌어도 전송 방식은 유지한다.

주 실험은 폭 0.5·0.75·1.0과 라운드당 최대 3개 경로 이동을 사용했다. 폭은 한 단계씩 바꾸며, 확대 조건은 두 라운드 연속 확인한다. 중계 용량 추정이 바뀐 라운드에는 폭을 유지한다.

경로별 전송 비율은 설정 용량과 공유 배정으로 계산하고, 경로 이동은 관측 용량으로 판단한다. 실행 결과는 다음 라운드의 측정값 갱신에 사용한다.

나. 여러 경로로 나눠 보내고 다시 합치는 과정

큰 텐서를 한 연결에 맡기면 해당 연결의 지연이 배치 전체의 대기로 이어질 수 있다. 전송 모듈은 활성값·기울기를 조각으로 나누고 연결별 예상 속도에 비례해 배분한다. 조각 크기는 전체 바이트를 연결 수의 16배로 나누되 64 KiB~1 MiB로 제한한다. 부가 정보 비용과 세밀한 부하 배분을 함께 고려한 설정이다.

하나의 텐서를 나누어 보내고, 원래 위치로 복원




그림 3. 지속 TCP 연결의 텐서 분할·재조립

1) 전송 조각의 형식과 부가 정보

표 4. 구현된 응용 메시지 프레임

구역	형식·길이	내용
고정 헤더	!BII · 9바이트	kind 1B · meta_len 4B payload_len 4B
메타데이터	JSON · 가변 길이	tid · cid · seq · off ln · total · ex
데이터	payload_len 바이트	직렬화된 텐서의 조각

전송 ID(tid)로 어느 텐서의 조각인지 구분한다. 조각 번호(seq)로 중복을 확인하고, 위치(off)와 길이(ln)로 저장할 구간을 정한다. 조각마다 9바이트 헤더와 JSON 정보가 추가된다. 연결별로 송신과 수신을 병렬 처리하며, 같은 소켓에 쓰는 작업에는 잠금을 두어 메시지가 섞이지 않게 한다.

2) 도착 순서가 바뀌어도 원래 텐서로 복원

수신부는 전체 텐서 버퍼의 지정된 위치에 조각을 저장해 도착 순서와 관계없이 재조립한다. 중복·겹침·길이 불일치를 검사하고 모든 조각이 도착하면 완성된 텐서를 학습에 전달한다. 분할 배분은 긴 전송 대기를 완화하기 위한 구조이며, 다음 계산은 전체 텐서의 수신을 기다린다.

3) 전송 완료 확인과 학습 모듈 연결

송신부는 다음 데이터를 보내면서 앞선 전송의 완료 회신을 확인한다. 라운드가 끝나면 flush로 남은 회신까지 확인한다. 서버의 기울기 전송은 별도 작업 스레드가 맡아 다른 처리가 소켓 대기로 지연되는 시간을 줄인다. 연결은 재사용하고 송신 버퍼 크기는 제한해, 느린 연결에 데이터가 과도하게 쌓이지 않게 한다.

전송 모듈은 전송 ID와 바이트열을 다루고, 학습 모듈은 텐서의 모양·자료형과 가중치 위치를 관리한다. 배치마다 텐서를 복원하고 라운드마다 모델을 집계하는 역할도 나누었다. 현재 변환 과정은 연속 버퍼와 데이터 복사를 사용한다. 학습 알고리즘은 연결과 재조립 코드를 바꾸지 않고 교체할 수 있다.

다. 실험용 회선 설정과 실제 장치 측정

실험은 HPC의 클라이언트 프로세스와 V100 학습 서버, VM 2대에 둔 논리 중계 4개로 구성했다. Linux tc로 클라이언트의 접속 상한과 중계의 공유 용량을 따로 설정했다. 반환 방향에도 같은 상한을 적용했다.

속도 제한에는 HTB를 사용하고 VM의 수신 트래픽은 IFB를 거치게 했다. 설정에 따른 지연은 netem으로 주입했으며, 중계 큐는 fq_codel을 사용했다.[11,12]

접속과 중계의 상한을 나누면, 여러 연결이 같은 회선을 사용하더라도 전체 속도가 회선 용량을 넘지 않는 조건을 만들 수 있다. 로컬 실험도 두 단계 HTB로 같은 구조를 구성했다. KOREN의 주 비교는 연결별 독립 접속 조건이므로 결과에 기준 연결 1개와 AwareNet 연결 2개를 명시했다.

두 정책에는 라운드 기록에 맞춰 같은 부하 변화를 적용했다. 트래픽 물림은 8라운드에 중계 용량을 56→14 Mbps로 줄이고 20라운드에 56 Mbps로 복구했다. 용량 변동은 7 Mbps 간격으로 낮추고 복구했다. 실행 조건, 시드, 사전 측정값과 라운드 로그를 보존해 설정과 결과를 대조할 수 있게 했다.[12,13]

Jetson Orin Nano Super 8GB에서는 전력 모드별 LoRA 학습 시간과 메모리 사용량을 따로 측정했다. KOREN 기록은 실제 통신 비용을, Jetson 기록은 장치의 연산 비용을 파악하는 데 사용했다. 모델과 실행 조건은 III장에 제시한다.

Ⅲ. 아이디어 개발 진행 내용 및 결과

1. 개발 수행 현황 및 최종 결과물

가. 하드웨어 부분

KOREN VM 두 대와 HPC의 CPU·V100 서버를 연결해 실제 텐서를 전송했다. 별도로 Jetson Orin Nano Super 8GB 한 대에서 Qwen2.5-0.5B LoRA의 전력 모드별 연산 특성을 측정했다. 랭크 32, FP32, 배치 1, 시퀀스 길이 256을 고정하고 워밍업 이후 모드별 30스텝을 분석했다.[13]

표 5. Jetson의 전력 모드별 스텝 시간 중앙값

전력 모드	스텝 시간	표본
MAXN SUPER	554.1 ms	30스텝
25 W	608.9 ms	30스텝
15 W	903.7 ms	30스텝

15 W 모드에서는 한 스텝이 MAXN SUPER보다 약 1.63배 오래 걸렸다. 같은 장비도 설정에 따라 속도가 달라지므로 실제 연산 시간을 측정해 스케줄링에 반영할 필요가 있다.

Jetson의 측정 전력(VDD_IN) 평균은 MAXN SUPER 11.969 W, 25 W 모드 10.985 W, 15 W 모드 8.852 W였다. 이 독립 실행으로 Qwen·LoRA의 실제 연산 시간과 전력 비용을 확보했다.[13]

나. 소프트웨어 부분

CNN 서브모델의 선택과 집계, 연산·전송 측정, 폭·경로 선택, TCP 전송과 텐서 복원을 구현했다. 실행 기록과 비교 결과를 보는 화면도 만들었다. FedRolex식 채널 순환 선택은 별도 300라운드 실행으로 검증했다. 학습 알고리즘을 바꾸기 쉽도록 모델 선택과 전송 제어를 분리했다.

LoRA 공동 학습은 KOREN VM 두 대의 논리 클라이언트 세 개와 HPC 서버에서 실행했다. Qwen2.5-0.5B·랭크 16·16라운드×30스텝에서 자체 18문항 중 단독 학습은 6개, 연합 집계는 12개를 맞췄다.[13] 별도 6라운드 전송 실험은 중계 배정을 조절해 어댑터 업로드 평균을 20.74초에서 16.75초로 줄였다. 랭크는 16으로 고정했다.[16]

2. KOREN 연동 및 활용 결과

가. KOREN의 활용

KOREN은 원격 자원을 연결하는 연구망으로 활용했다. HPC와 VM 사이에서 학습 텐서를 실제로 주고받아, 연산 시간뿐 아니라 전송 대기과 텐서 복원까지 포함한 완료 시간을 측정했다. 네트워크를 통한 분할 학습의 비용을 확인하고 반복 비교할 기반을 제공했다.[10]

VM 두 대에 중계를, HPC에 클라이언트와 V100 학습 서버를 배치했다. 클라이언트 프로그램에서 중계 배정과 전송 비율을 바꾸어 서로 다른 경로의 부하를 조절했다. 이번 제어 범위는 이러한 종단·중계 프로그램이며, KOREN 내부 라우터의 경로 설정은 포함하지 않는다.

안정적인 연구망에서도 동시 전송이 늘면 지연은 커졌다. 8개와 32개 클라이언트의 배치 왕복 시간 중앙값은 각각 0.41초와 2.18초였다. 이 관측을 출발점으로 회선 용량과 부하 변화 시점을 정하고, CPU와 메모리 한도에 맞춰 축소 실험을 반복했다. 실제 경로에서 확인한 병목을 통제 가능한 조건으로 옮겨 대응 정책을 비교한 것이다.

나. T-SDN·L2VPN을 활용한 후속 확장

추가 망 제어는 현재의 중계 선택과 별도로 확장한다. 운영기관이 허용한 구간에서는 SDN 제어기로 스위치 전달 규칙을 설정하고, 적용 결과를 확인한 뒤 스케줄러와 연결할 수 있다. OS-Ken 어댑터는 이 후속 연동을 위한 코드다.[14]

KOREN의 T-SDN·L2VPN은 이용 조건을 협의해 적용할 후속 방안이다.[10] T-SDN의 제공 경로·회선 정보를 스케줄러에 반영하고, L2VPN으로 기관별 클라이언트와 중계를 논리망에 연결하는 구성을 검토한다.

확보한 전송 여유는 모델 폭을 유지할 기회로 활용한다. 후속 검증에서는 같은 연결 수와 학습 조건에서 중앙값·95백분위 완료 시간, 목표 정확도 도달 시간을 비교한다. L2VPN 연결 자체와 대역폭 보장은 구분하고, 허용된 망 설정만 연동한다.

다. 실제 경로의 관측과 축소 실험

먼저 별도의 속도 제한을 설정하지 않고 HPC에서 KOREN VM을 거치는 텐서 전송을 측정했다. 동시 전송 수를 8~96개로 늘려 실제 경로에서 전송이 집중될 때 완료 시간이 어떻게 변하는지 확인했다. 이 측정은 이후 부하 조건을 축소해 반복 비교하는 실험의 출발점이다.[11]




그림 4. KOREN 중단 간 경로의 동시 전송 규모별 완료 시간

배치 왕복 시간의 중앙값은 8개에서 0.41초, 32개에서 2.18초로 늘었다. 양호한 망에서도 여러 클라이언트가 동시에 보내면 학습이 지연될 수 있다는 결과다. 이는 HPC와 접속 회선, VM을 모두 포함한 측정이므로 지연을 KOREN 코어 장비의 영향으로만 해석할 수는 없다.

이 현상을 반복해서 평가하기 위해 SHRiNK의 축소 실험 방식을 참고했다.[9] 많은 학습 프로세스를 오래 실행하면 CPU와 메모리가 부족해져, 32개 논리 클라이언트로 단기 제어를 확인하고 8개로 장기 학습을 수행했다. 회선 속도와 부하를 함께 조정해 제한된 자원에서도 혼잡과 복구 과정을 관찰했다.

대역폭을 0.1배로 조정한 조건과 클라이언트를 32→8개로 줄인 조건은 구분해 기록했다. 각각 회선과 계산 자원을 조정한 별도 실행이므로 시간도 따로 비교한다. 규모와 부하 조건은 다음 표에 정리했다.

라. 실험 조건과 라운드 완료 시간

표 6. 제어 응답 및 장기 학습의 실행 조건

항목	단기 제어 평가	장기 학습 평가
공통 모델·배치	ResNet-18 / CIFAR-10 분할 위치 2 / 배치 32	ResNet-18 / CIFAR-10 분할 위치 2
규모·반복	32개 논리 클라이언트 24라운드×3시드	8개 논리 클라이언트 200라운드×2시드
실행 배치	HPC CPU 클라이언트·V100 서버 KOREN VM 2대, 논리 중계 4개	동일 연구망 기반의 축소 실행 학습 품질까지 장기 관찰
교란·설정	정상 / 한 중계 1/4 용량 4개 클라이언트 연산 지연 / 용량 변동	$\lambda=18 \cdot 70 \cdot 280$ 실행별 조건은 E7·E8에 수록

단기 평가: 라운드당 4배치, 접속 상한 5/2 Mbps, 정상 중계 용량 각 56 Mbps, 폭 후보 0.5·0.75·1.0, $\lambda=70$, 라운드당 이동 최대 3개. 장기 평가도 라운드당 4배치를 사용했다.




그림 5. 조건별 평균 라운드 완료 시간

트래픽 몰림에서는 라운드 시간이 109.51초에서 62.87초로 줄어 42.6% 단축됐다. 이때 평균 폭은 0.998로 대부분 유지했다. 연산 지연에서는 느린 클라이언트 4개의 폭을 0.75로 줄였고, 시간이 79.12초에서 47.26초로 40.3% 짧아졌다. 두 상황에 서로 다른 설정을 적용한 결과다.[11]

기준 방식은 연결 1개, AwareNet은 2개를 사용한 전체 구성 비교다. 실제 전송량 감소는 최대 3.12%였다. 추가 로컬 진단에서는 연결 2개를 맞추고 4조건·6정책·3반복을 비교했다. 혼합 병목에서 결합 정책은 독립 제어와 비슷한 시간에 더 큰 평균 폭을 유지했다.[16]

3. 멘토 의견에 따른 개선사항

멘토 의견은 개발 목표와 실증 범위를 구체화하는 계기가 됐다. 기존 중간보고서의 7월 12일, 7월 30일, 8월 6일 기록은 클라이언트 참여, 혼잡제어와의 경계, 실제 환경 검증, 관측값의 지속성에 대한 검토를 담고 있다.[12]

표 7. 멘토 의견과 반영 내용

기존 기록의 의견	반영 내용
미선택 클라이언트의 기여를 어떻게 볼 것인가	참여 배제보다 클라이언트의 학습 부담과 완료 시간 조정에 집중
혼잡제어와의 경계가 불분명하다	TCP의 패킷 제어와 라운드 단위 모델·중계 선택을 분리
시뮬레이션만으로는 실증이 부족하다	KOREN 실제 전송과 Jetson 장비 측정을 수행
관측 가치가 지속되는가, LoRA가 초점을 흐린다	상태를 반복 관측하고 CNN 제어 평가와 LoRA 확장 실습을 구분

모델 축소에 따른 정확도 문제를 검토하며 채널 순환 선택과 축소 비용 λ 를 추가했다. 경로 선택에는 실제 전송량과 소요 시간, 공유 회선의 상한을 반영했다. 각 설정에서 얼마나 빨리 학습을 마칠 수 있는지 비교하는 방식으로 구현했다.

운영기관이 다른 클라이언트와 중계는 허용된 주소·포트로 연결한다. 현재의 중계 선택은 응용 프로그램에서 수행하며, 스위치 규칙 변경은 권한 협의와 별도 연동 검증이 필요한 후속 작업이다. 기관의 운영 정책에 맞춰 인증·암호화·접근통제를 갖추고 활성값의 정보 노출 위험을 평가한다.

다음 검증은 텐서 분할 자체의 효과에 집중한다. 모델·경로·연결 수를 고정하고 텐서 통째 전송, 균등 분할, 전송률 비례 분할을 비교한다. 텐서 완료 시간의 95백분위수와 마지막 조각 대기를 측정한다. 이어 목표 정확도 도달 시간과 LoRA의 동적 모델 조절을 평가한다.

4. 결과물의 통합 및 시험/검증 결과

가. 장기 학습과 품질 검증

λ 는 모델을 얼마나 신중하게 줄일지 정하는 값이다. 큰 값은 폭 유지에, 작은 값은 시간 단축에 더 비중을 둔다. 8클라이언트·200라운드 실험에서 λ 를 바꾸어 시간과 정확도를 비교했다. 시간은 초기 4라운드를 뺀 평균, 정확도는 마지막 50라운드의 평균이며 두 시드의 결과를 다시 평균했다. 평가에는 테스트셋의 앞 2,000개 표본을 사용했다.[11]

표 8. 축소 가중치에 따른 시간과 정확도

설정	라운드 시간	평균 폭	정확도	시간 단축
기준선	19.11초	1.000	65.52%	—
$\lambda=280$	15.15초	1.000	65.22%	20.7%
$\lambda=70$	12.90초	0.977	63.17%	32.5%
$\lambda=18$	8.01초	0.832	53.59%	58.1%

$\lambda=280$ 에서는 폭을 유지한 채 시간이 20.7% 짧아졌고 정확도 차이는 약 -0.29% 였다. λ 를 낮추면 모델을 더 줄여 시간이 짧아졌지만 정확도 손실도 커졌다. 따라서 λ 는 원하는 속도와 실제 학습 품질을 함께 보고 선택해야 한다. 이 결과는 경로 변경의 여유를 먼저 살피고 모델 축소를 신중히 적용할 필요성을 보여준다.

채널 선택 개선은 별도의 4클라이언트·300라운드×3시드에서 검증했다.[12] 이 실험은 FedRolex식 순환 추출과 집계 기법의 구현 근거다.

표 9. Fashion-MNIST 추가 학습의 정확도와 텐서 크기

방식	정확도 (%)	텐서 바이트 비율
전폭	82.53 ± 0.64	1.00
고정 채널	82.19 ± 0.72	0.75
순환 채널	81.24 ± 0.61	0.75

3클라이언트·100라운드·라운드당 8스텝·3시드로 학습하고 시험 표본 10,000개를 평가했다. 표는 최종 정확도 평균±시드 표준편차와 전폭 대비 텐서 바이트 비율이다. 동일 초기값·배치 순서를 사용한 로컬 학습으로, 순환 선택의 우위는 나타나지 않았다. 텐서는 메모리 내에서 전달했다.[16]

나. CNN과 LoRA의 학습·추론 시연

활용 시연은 AwareNet 안에서 공개 X-ray 분류와 가상 기업의 업무 문답을 학습하고, 클라이언트별 결과를 집계한 뒤 공동 모델로 예측하는 흐름으로 구성했다. 실행 로그·집계 결과·저장 모델의 추론 출력을 보존했다. 시연 데이터와 학습 조건은 앞의 KOREN 실험과 구분한다.[15]

표 10. 최종 시연의 실행 조건과 결과

항목	CNN 영상 분류	LoRA 업무 문답
데이터	PneumoniaMNIST+ 학습 4,708장 / 시험 624장	가상 규정 9개 학습 54문장 / 평가 18문항
모델	ResNet-18 채널 비율 0.5·0.75·1.0	Qwen2.5-0.5B LoRA 랭크 16
실행	20라운드 클라이언트당 12스텝	16라운드 클라이언트당 12스텝
결과	시험 정확도 87.02% 543/624 일치, 오분류 81장	기본 0/18 · 단독 6/18 연합 18/18

CNN은 같은 시험 영상의 학습 전·후 예측을 비교했다. 저장 모델을 다시 불러왔을 때도 624개 예측이 일치했다. LoRA는 세 부서의 규정을 나눠 학습한 뒤 같은 질문에 대한 답을 비교했다. 학습한 규정을 다른 표현으로 묻는 자체 평가이므로 일반 업무 성능으로 넓혀 해석하기는 어렵다. 병원 사례도 공개 연구용 영상의 분류 시연이다.

시연 화면에서는 클라이언트별 학습 손실과 정확도, 생성된 답변을 볼 수 있다. KOREN 기록에서는 경로와 폭이 바뀐 시점을 확인할 수 있다. 두 실행의 조건과 출처를 구분해 표시했으며, 이 화면을 연속 녹화해 시연 영상으로 만들었다.

다. 모델별 실험과 원자료

ResNet-18은 CNN 계열의 모델이며, LoRA는 Qwen 언어모델에 적용한 학습 기법이다. 모델 이름과 조절 대상을 구분하고, 학습 성능·전송 제어·장치 측정을 아래와 같이 연결했다. 실험마다 데이터와 평가 범위가 다르므로 각 행의 조건 안에서 비교한다.

표 11. 모델과 학습 기법별 실험 총괄

모델·학습 기법	데이터·조건	비교 결과	근거
ResNet-18 CNN 분할 학습	CIFAR-10 32클라이언트·24R·3시드	기준 대비 라운드 시간 24.6~42.6% 단축 연결 1개와 2개 구성 비교	E1·E8
ResNet-18 CNN 장기 학습	CIFAR-10 8클라이언트·200R·2시드	$\lambda=280$: 19.11→15.15초 정확도 65.52→65.22%	E7·E8
ResNet-18 채널 선택 비교	Fashion-MNIST 3클라이언트·100R·3시드	전폭 82.53%, 고정 82.19% 순환 81.24% 축소 텐서 크기 75%	F1
ResNet-18 영상 분류 시연	PneumoniaMNIST+ 3클라이언트·20R	공동 모델 543/624 정답 87.02%	D1
Qwen2.5-0.5B LoRA 분할 학습	자체 문답 18개 3클라이언트·16R·랭크 16	미학습 0/18 → 단독 6/18 연합 집계 12/18	E4
Qwen2.5-0.5B LoRA 업무 시연	가상 기업 지침 3클라이언트·16R·랭크 16	미학습 0/18 → 단독 6/18 연합 집계 18/18	D1
Qwen2.5-0.5B LoRA 어댑터 전송	3클라이언트·6R 랭크 16 고정	고정 배정 20.74초 경로 제어 16.75초 업로드 시간 19.3% 단축	L1
Qwen2.5-0.5B Jetson 연산 실측	랭크 32·FP32 배치 1·길이 256	전력 모드별 스텝 중앙값 554.1 / 608.9 / 903.7ms 독립 연산·전력 측정	E2

E1·E2·E4·E7·E8은 공개 원자료 색인, F1은 Fashion-MNIST 조건·예측·학습 로그, D1은 시연 실행 로그, L1은 LoRA 업로드 원로그다. 각 파일과 집계 기준은 아래의 실험 비교 자료 페이지에서 바로 확인할 수 있다.[17]

라. 기능을 켜고 끈 실제 학습 비교

기존 CIFAR-10 실험에서 폭 조절, 중계 배정, 다중 연결 분할 전송을 선택적으로 활성화했다. 8클라이언트·24라운드·3시드, 중계 용량 125 Mbps×4의 기록을 재집계했다. 이 실험은 10초 목표를 사용하는 이전 제어 방식으로, 앞의 λ 기반 평가와 구분한다.

표 12. 기능 활성화에 따른 시간과 정확도

설정	폭	경로	분할	시간(초)	평균 폭	정확도(%)
기준 방식	끔	고정	끔	18.95	1.000	24.61
폭만	끔	고정	끔	9.36	0.568	17.34
경로+분할	끔	끔	끔	14.48	1.000	26.39
폭+경로	끔	끔	끔	9.22	0.813	23.05
폭+경로+분할	끔	끔	끔	9.29	0.927	26.32

시간과 평균 폭은 초기 10라운드를 제외한 평균, 정확도는 마지막 20라운드 평균을 계산한 뒤 세 시드를 평균했다. 평균 폭은 라운드 로그의 plan 값을 사용했다. 각 실험의 설정 파일과 24개 라운드 원기록을 함께 공개했다.[17]

폭+ 경로와 폭+ 경로+ 분할은 각각 9.22초와 9.29초로 비슷했다. 분할을 포함한 구성은 평균 폭 0.813 대신 0.927을 유지했고, 정확도는 23.05%에서 26.32%로 높았다. 이 조건에서는 더 작은 모델로 시간을 줄이는 선택보다 전송 자원을 함께 사용하는 선택이 모델 크기를 보존하는 데 유리했다.

분할 활성화는 연결 수도 바꾸므로 이 표는 기능 구성 간 비교다. 텐서 조각 크기만의 효과는 별도 비교가 필요하다. 또한 24라운드의 정확도는 단기 학습 지표로 해석한다.

같은 연결 수의 보조 검증

별도의 로컬 TCP 진단은 모든 정책에 연결 2개를 적용해 고정·정적 분산·경로만·폭만·독립·결합을 4조건×3회 비교했다. 혼합 병목에서 독립 제어는 0.927초·평균 폭 0.667, 결합 제어는 0.934초·0.833이었다. 이 기록은 소켓 전송과 제어 판단을 확인하며, 모델 정확도는 위의 실제 학습 결과로 따로 평가한다.[16]

IV. 결 론

1. 개발 최종 결과물

AwareNet은 모델 폭, 중계 경로와 텐서 분할 전송을 함께 조절한다. 큰 텐서를 연결별 처리 능력에 맞춰 배분하고, 경로 조정 후의 예상 시간으로 모델 축소의 필요성을 판단한다. 공유 회선 용량을 반영하고 용량 변화 직후에는 폭을 유지한다. 전송 경합을 완화하면서 불필요한 모델 축소를 줄이는 구조다.

KOREN에서 동시 전송에 따른 지연을 확인한 뒤 축소 실험으로 제어를 평가했다. 32클라이언트 구성은 평균 라운드 시간이 24.6~42.6% 짧아졌다. 8클라이언트 장기 평가에서는 폭을 유지하면서 20.7% 단축과 약 $-0.29\%p$ 의 정확도 차이를 확인했다. Jetson의 실제 연산 측정과 LoRA 공동 학습으로 다른 장치와 모델의 적용 가능성도 살폈다.

2. 기술 구현에 따른 기대 효과




그림 6. 여러 기관의 전역 모델 공동 개선 활용 예시

병원이나 제조 현장마다 계산 자원과 접속 환경이 다르다. 통신이 혼잡하면 여유 있는 중계 경로를 이용하고, 계산 부담이 크면 모델 크기를 조절해 공동 학습의 대기를 줄일 수 있다. 이 과정에서 일부 기관이 계속 작은 모델만 학습하지 않는지도 살펴야 한다.

이러한 스케줄링은 더 다양한 기관이 정해진 시간 안에 모델 갱신에 참여할 여건을 만든다. 각 기관의 데이터가 반영된 공동 모델을 꾸준히 개선하도록 돕는 것이 기대 효과다. 병원 적용은 향후 활용 시나리오이며, 현재는 KOREN의 CNN 학습, Jetson·LoRA 실행과 공개 데이터 시연으로 검증했다.

V. 참고문헌

- [1] H. B. McMahan 외. Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS, 2017.
<https://proceedings.mlr.press/v54/mcmahan17a.html>
- [2] C. Thapa 외. SplitFed: When Federated Learning Meets Split Learning. AAAI, 2022.
<https://arxiv.org/abs/2004.12088>
- [3] S. Horváth 외. FjORD: Fair and Accurate Federated Learning under heterogeneous targets with Ordered Dropout. NeurIPS, 2021.
<https://arxiv.org/abs/2102.13451>
- [4] S. Alam 외. FedRolex: Model-Heterogeneous Federated Learning with Rolling Sub-Model Extraction. NeurIPS, 2022.
<https://arxiv.org/abs/2212.01548>
- [5] Z. Lin 외. AdaptSFL: Adaptive Split Federated Learning in Resource-constrained Edge Networks. arXiv:2403.13101v4. 시간 분석 §V-A.
<https://arxiv.org/abs/2403.13101v4>
- [6] A. Al Asif 외. SuperSFL: Resource-Heterogeneous Federated Split Learning with Weight-Sharing Super-Networks. arXiv:2601.02092v2, 2026.
<https://arxiv.org/abs/2601.02092v2>
- [7] Z. Lin 외. SplitLoRA: A Split Parameter-Efficient Fine-Tuning Framework for Large Language Models. arXiv:2407.00952, 2024.
<https://arxiv.org/abs/2407.00952>
- [8] E. J. Hu 외. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
<https://arxiv.org/abs/2106.09685>

참고문헌 및 실험 원자료

[9] R. Pan 외. SHRiNK: A method for scaleable performance prediction and efficient network simulation. IEEE INFOCOM, 2003.

<https://web.stanford.edu/~balaji/papers/03shrinkaCONF.pdf>

[10] NIA. KOREN(지능형 연구개발망) 이용안내서, 6-9쪽: 연구망 및 T-SDN·L2VPN 서비스. 열람 2026.09.30.

<https://sanhak.duksung.ac.kr/attach/download/1826>

[11] AwareNet. KOREN line_scale 원로그, scen32 및 r8mix_acc 실행 기록. 지표 정의와 원파일 경로는 report_metrics_revised.json, 공개 색인 E1·E3·E7·E8.

<https://sijoon-sung.github.io/AwareNet/site/evidence.html>

[12] AwareNet. 설계기록_컨트롤러, 정식화_결합_시스템, 방향검토보고서, 설계전환_회의록. FjORD/FedRolex 적용 이력, verify2.log, w25r·w50r 실행 기록. 공개 색인 E9.

<https://sijoon-sung.github.io/AwareNet/site/evidence.html#E9>

[13] AwareNet. Jetson 스텝·전력 모드 기록과 LoRA 학습·메모리·문답 평가.

Jetson 복구 커밋 582b1d4. final_report_evidence_2026-09-26.json과 공개 색인 E2·E4.

<https://sijoon-sung.github.io/AwareNet/site/evidence.html#E2>

[14] OpenStack. Writing Your OS-Ken Application. 공식 문서.

https://docs.openstack.org/os-ken/latest/writing_os_ken_app.html

[15] AwareNet. 공개 X-ray 및 가상 업무 규정의 로컬 학습·추론 기록.

2026.09.29. PneumoniaMNIST+ : Yang 외, MedMNIST v2, CC BY 4.0.

<https://sijoon-sung.github.io/AwareNet/site/demo.html>

[16] AwareNet. 추가 검증 및 선행연구 대조, 2026.10.01. Fashion-MNIST 100라운드·3시드, 동일 연결 수 72회 전송 진단 및 조건·원로그·코드.

<https://sijoon-sung.github.io/AwareNet/site/followup.html>

[17] AwareNet. 모델별 실험 및 기능 제거 비교. 원로그·실행 인자·프로파일·재집계 코드, 2026.10.01.

<https://sijoon-sung.github.io/AwareNet/site/comparisons.html>