

K-디지털 챌린지 : 넷 챌린지 캠프 시즌13

최종결과보고서

분할 연합학습을 위한
모델과 네트워크의 적응형 스케줄링

AwareNet

본 보고서를 K-디지털 챌린지 : 넷 챌린지 캠프 시즌13의
최종결과보고서로 제출합니다.

2026년 9월 30일

참여 구성원
성시준 · 석태경
충남대학교 전파정보통신공학과

한국지능정보사회진흥원장 귀하

안 내 사 항

1. 본 연구보고서는 한국지능정보사회진흥원의 출연금으로 수행한 K-디지털 챌린지 : 넷 챌린지 캠프 시즌13의 연구망 활용 연구과제 결과입니다.
2. 본 연구보고서의 내용을 발표할 때에는 반드시 한국지능정보사회진흥원 K-디지털 챌린지 : 넷 챌린지 캠프 시즌13의 연구망 활용 연구과제 결과임을 밝혀야 합니다.

요 약 문

1. 제 목

AwareNet 분할 연합학습을 위한 모델과 네트워크의 적응형 스케줄링

2. 아이디어 개발의 목적 및 필요성

데이터를 기관 밖으로 모으기 어려운 환경에서 연합학습은 각 클라이언트의 모델 갱신을 모아 전역 모델을 구축한다. 분할 연합학습은 모델의 연산을 서버와 나누어 클라이언트의 자원 부담을 줄이지만, 배치마다 활성값과 기울기를 교환하므로 통신 지연에 민감하다. 본 프로젝트는 연산 병목과 네트워크 병목에 맞춰 모델 축소와 전송 경로를 함께 조절한다.

3. 아이디어 개발의 내용 및 범위

AwareNet은 허용 중계의 경로 조정으로 줄일 수 있는 지연을 먼저 평가한 뒤, 그 배정에서도 남는 지연의 감소와 모델 축소 비용을 비교한다. 공유 접속·중계 용량을 반영하고 관측 용량이 바뀐 라운드에는 폭을 유지해 과도한 동시 조정을 억제한다. 선택한 설정은 CNN 서브모델과 다중 연결 텐서 전송에 적용하며, 고정 랭크 LoRA는 분할 실행·집계의 확장 실습으로 검증했다.

4. 개 발 결 과

KOREN의 실제 종단 간 경로에서 동시 전송에 따른 지연을 확인한 뒤, CPU·메모리 제약 안에서 축소 실험을 수행했다. 32개 논리 클라이언트·3시드 평가에서 트래픽 몰림과 연산 지연 조건의 라운드 시간이 각각 42.6%, 40.3% 짧았다. 별도의 8클라이언트·200라운드 평가에서는 채널 비율을 유지한 설정에서 20.7% 단축과 약 -0.29%p의 정확도 차이를 관측했다. 수치는 기준 1개 연결과 결합 구성 2개 연결을 포함한 전체 구성 비교다.

5. 기 대 효 과

병원·제조기관처럼 데이터와 자원이 분산된 환경에서 공동 학습의 대기를 줄이고 다양한 클라이언트가 전역 모델 갱신에 참여하도록 지원한다. 실제 적용에서는 기관별 권한, 통신 보안과 목표 정확도를 함께 관리한다.

목 차

I. 서 론	6
1. 개발 목적 및 필요성	6
2. 특징	7
II. 아이디어 개발 추진 내용과 범위	8
1. 개발 목표 및 추진 내용	8
2. 단계별 세부 구현 계획	11
III. 아이디어 개발 진행 내용 및 결과	15
1. 개발 수행 현황 및 최종 결과물	15
2. KOREN 연동 및 활용 결과	16
3. 멘토 의견에 따른 개선사항	18
4. 결과물의 통합 및 시험/검증 결과	19
IV. 결 론	21
1. 개발 최종 결과물	21
2. 기술 구현에 따른 기대 효과	21
V. 참고문헌	22

그림 목차

- 그림 1. 스케줄러와 KOREN 실험 구성 8
- 그림 2. 라운드 단위 제어 파이프라인과 피드백 11
- 그림 3. 지속 TCP 연결의 텐서 분할·재조립 13
- 그림 4. KOREN 중단 간 경로의 동시 전송 규모별 완료 시간 16
- 그림 5. 조건별 평균 라운드 완료 시간 17
- 그림 6. 여러 기관의 전역 모델 공동 개선 활용 예시 21

표 목차

- 표 1. 선행연구의 제어 대상과 AwareNet의 설계 초점 7
- 표 2. 공통 시스템에 연결한 두 학습 구현 9
- 표 3. 제어 단계별 입력과 출력 11
- 표 4. 구현된 응용 메시지 프레임 13
- 표 5. Jetson의 전력 모드별 스텝 시간 중앙값 15
- 표 6. 제어 응답 및 장기 학습의 실행 조건 17
- 표 7. 멘토 의견과 반영 내용 18
- 표 8. 축소 가중치에 따른 시간과 정확도 19
- 표 9. 모델 조절 방식과 제어 평가의 관계 19
- 표 10. 최종 시연의 실행 조건과 결과 20

I. 서론

1. 개발 목적 및 필요성

의료·제조 분야에서는 데이터 프라이버시와 기관별 관리 정책 때문에 원자료를 한곳에 모으기 어렵다. 연합학습(Federated Learning, FL)은 데이터를 클라이언트에 보관하면서 모델 갱신을 집계해 공동 모델을 구축하는 접근법이다.[1] 그러나 전체 모델을 학습하는 데 필요한 연산량과 메모리는 자원이 제한된 클라이언트의 참여를 어렵게 한다.

분할 연합학습(Split Federated Learning, SFL)은 이러한 부담을 줄이기 위해 모델의 앞부분을 클라이언트에, 뒷부분을 서버에 배치하고 연합 집계를 결합한다.[2] 대신 배치마다 중간 활성화값(activation)과 기울기(gradient)를 교환한다. 따라서 이질적인 연산 성능뿐 아니라 네트워크 병목에 따른 통신 지연도 학습 속도에 영향을 준다. 동기식 구조에서는 가장 늦게 완료되는 클라이언트, 즉 스트래글러(straggler)가 전체 라운드 시간을 결정한다.

모델 폭(width)을 조절하는 서브모델(submodel) 학습은 연산량과 전송량을 줄이는 방법이다.[3,4] 다만 모델 표현력과 파라미터 갱신 빈도가 달라져 정확도가 낮아질 수 있다. 네트워크 경합 때문에 지연된 클라이언트까지 일괄 축소하면, 전송 경로를 조정해 해소할 수 있는 지연에도 모델 용량을 줄이게 된다. 반대로 클라이언트의 연산 자원이 부족하거나 대체 경로도 공유 회선의 상한에 묶여 있으면 경로 전환만으로 지연을 충분히 줄이기 어렵다.

본 프로젝트는 연산 병목과 네트워크 병목에 필요한 조치가 다르다는 점에 주목한다. AwareNet은 클라이언트 연산 시간과 경로별 실효 전송률을 관측하고, 모델 폭과 허용 중계 경로를 바꿀 때의 예상 완료 시간을 비교한다. 네트워크의 여유를 활용하면서 모델 축소에는 비용을 부여해 불필요한 축소를 줄인다. 목표는 학습 품질을 함께 확인하며 동기식 라운드의 완료 시간을 단축하는 것이다.

2. 특징(동일·유사 아이디어에 대한 차별성·독창성·혁신성)

동일한 통신 지연도 경로 재배정으로 줄일 수 있는 경우와 공유 회선의 상한에 묶인 경우가 있다. 지연만 보고 모델을 축소하면 전자에서는 학습 용량을 불필요하게 줄인다. AwareNet은 이 문제를 모델 선택과 중계 배정을 함께 평가하는 교차 계층 스케줄링(cross-layer scheduling)으로 다룬다.

가. 차별성: 모델 선택에 네트워크 경로를 결합

FjORD·FedRolex는 이질적인 클라이언트의 서브모델 학습을, AdaptSFL·SuperSFL은 통신·연산 자원에 따른 SFL 구성을 다룬다.[3-6] 본 프로젝트는 고정된 모델 분할점에서 허용 중계 배정과 전송 분할비까지 조절한다. 경로를 바꾼 후보의 완료 시간으로 폭 축소의 필요성을 판단하는 것이 설계의 중심이다.

표 1. 선행연구의 제어 대상과 AwareNet의 설계 초점

접근	주요 제어 대상	설계 초점
FjORD FedRolex	서브모델 크기·추출	이질적인 모델의 학습
AdaptSFL SuperSFL	분할·집계 또는 서브네트워크	통신·연산 자원 적응
AwareNet	폭·허용 중계·전송비	경로 개선 후 축소 판단

나. 독창성: 공유 병목과 제어 간섭을 반영한 판단

연결별 전송률은 공유 중계 용량과 클라이언트 접속 상한을 동시에 만족하도록 계산한다. 이를 바탕으로 경로 개선 이득과 폭 축소 이득을 같은 시간 단위로 비교한다. 이동 완료 후의 목표 배정으로 축소를 판단하고, 관측 용량이 바뀐 라운드에는 폭을 유지한다. 이 조합은 경로 이동 중의 일시적인 지연이 과도한 모델 축소로 이어지는 것을 억제한다.

다. 실용성: 모듈 분리와 실제 환경의 검증

학습 모듈, 응용 계층 전송, 관리망 집행을 분리해 기관별 권한 범위에 배치한다. KOREN의 실제 텐서 전송과 장기 CNN 학습으로 시간·정확도를 평가했으며, Jetson의 하드웨어 프로파일과 고정 랭크 LoRA 분할·집계로 다른 장치·모델에 필요한 비용 특성을 확인했다. 결과 수치와 각 실험의 연결 범위는 III장에 제시한다.

II. 아이디어 개발 추진 내용과 범위

1. 개발 목표 및 추진 내용

가. 개발 목표

본 프로젝트의 목표는 이질적인 클라이언트가 참여하는 동기식 SFL에서 학습 품질을 유지하며 라운드 완료 시간(makespan)을 단축하는 것이다. 이를 위해 최대 예상 완료 시간과 모델 폭 감소 비용을 결합한 목적함수 J 를 정의한다. 허용 중계와 접속 용량 제약 안에서 폭·경로 후보를 선택하고, 시간 이득과 정확도 변화의 관계를 장기 학습으로 평가한다.

나. 세부 추진 내용 및 범위

AwareNet 전체 구조




그림 1. 스케줄러와 KOREN 실험 구성

시스템은 관측부, 계획부, 실행부의 폐루프로 구성한다. 관측부는 연산 프로파일과 연결별 전송 기록을 모은다. 계획부는 공유 회선의 상한 아래에서 모델 크기와 중계 배정을 선택한다. 실행부는 다음 라운드에 서버모델과 연결별 조각 비율을 적용하고 실제 완료 시간을 다시 관측부에 전달한다.

응용 계층의 오버레이 경로는 사용할 중계 호스트를 뜻한다. 이 경로와 텐서 전송은 학습 프로그램이 제어하고, 관리 호스트의 트래픽 제어는 반복 실험의 회선 조건을 집행한다. OS-Ken 어댑터는 운영자가 권한을 부여한 SDN 구간에 연결하는 확장 인터페이스다. 학습·전송·망 집행을 분리해 기관별 권한 범위에 맞춰 배치한다.

1) 순환 서브모델 추출과 모델 폭 제어

모델 폭은 한 계층이 사용하는 유닛 수이며, CNN에서는 채널 수로 표현한다. AwareNet의 계획부는 사용할 채널의 비율을 정하고 학습 모듈은 실제 채널 인덱스를 선택한다. 따라서 스케줄러가 결정하는 서브모델의 크기와 학습 알고리즘이 결정하는 갱신 위치를 독립적으로 바꿀 수 있다.

고정 선택은 같은 폭에서 같은 채널을 반복 사용하므로, 작은 서브모델만 학습하는 클라이언트의 갱신이 특정 파라미터에 집중될 수 있다. FedRolex식 순환 선택은 라운드마다 채널 인덱스를 이동하고 원래 위치에 맞춰 갱신을 집계한다.[4] 본 구현은 고정·순환 선택을 지원하며, 순환 추출과 집계는 별도 300라운드 실행으로 검증했다. CNN의 계층 수와 클라이언트·서버 분할 위치는 고정한다.

2) CNN·LoRA의 모듈 인터페이스와 검증 범위

CNN은 채널 수를 바꿀 때 연산량과 분할 활성값 크기가 함께 변하므로 결합 제어를 평가하는 기준 모델로 사용한다. 새 학습 알고리즘을 적용하려면 모델 설정별 연산 시간, 전송 바이트와 집계 규칙을 제공하면 된다. 이 인터페이스를 두어 특정 채널 선택 방법에 전송 구조가 종속되지 않도록 했다.

표 2. 공통 시스템에 연결한 두 학습 구현

구분	CNN 서브모델 학습	LoRA 언어모델 학습
자원 조절 변수	채널 비율·선택 위치	추가 학습 행렬의 랭크
전송량과의 관계	채널 수에 따라 활성값·기울기 크기 변화	랭크는 어댑터 집계량에 영향 분할 활성값 차원은 유지
검증 목적	폭·경로 제어의 시간·정확도 별도 채널 순환 선택	고정 랭크의 분할 실행 메모리 사용·연합 집계

LoRA는 기반 가중치를 고정하고 저랭크 행렬을 학습한다.[7,8] 언어모델 실습에서는 고정 랭크의 앞부분 어댑터를 집계하고 서버의 뒷부분을 공동 갱신했다. 이 결과는 학습 모듈의 확장 근거이며, CNN에서 측정한 동적 폭·경로 제어와는 검증 목적이 다르다. 랭크를 동적으로 선택하려면 랭크별 비용 프로파일을 추가한다.

3) 목적함수와 단계적 최적화

클라이언트 i 의 한 배치 시간은 연산 C_i , 활성화 전송 U_i , 서버 처리 S_i , 기울기 반환 D_i 로 구성한다. B 는 라운드당 배치 수, T_0 는 모델 배포·집계 시간이다. 서버 대기 S_i 에 포함하면 동기식 라운드 시간은 다음과 같이 나타낼 수 있다.[2,5]

$$\tau_i = C_i + U_i + S_i + D_i \quad (1)$$

$$T_{round} \approx T_0 + \max_i (B \cdot \tau_i) \quad (2)$$

폭 비율 w_i 와 중계 배정 P 의 예상 시간을 식 (3)으로 계산한다. c_i 와 b_i 는 전폭의 배치당 연산 초과 왕복 전송 바이트, R_i 는 배정에 따른 실효 전송률(bit/s), o_i 는 고정 처리·관측 잔차다. γ_i 는 폭에 따른 연산 시간의 지수이며 프로파일의 기본값은 1.2다.

$$\hat{T}_i(w_i, P) = B [c_i w_i^{\gamma_i} + \frac{8 b_i w_i}{R_i(P)} + o_i] \quad (3)$$

R_i 는 중계 용량을 공유하는 흐름의 몫과 접속 상한으로 정한다. 공유 접속이면 연결들의 합에 상한을, 독립 접속이면 각 연결에 상한을 적용한다. 이 계산으로 경로 변경의 시간 이득과 모델 축소의 시간 이득을 같은 단위에서 비교한다.

$$J(w, P) = \max_i \hat{T}_i + \frac{\lambda}{N} \sum_i (1 - w_i) \quad (4)$$

N 은 클라이언트 수이고 λ 는 평균 폭 감소에 부여하는 비용으로 단위는 초다. λ 가 크면 더 큰 시간 이득이 있어야 축소를 선택한다. 축소 전후 최대 시간 차이를 ΔT , 평균 폭 감소를 $\Delta \bar{w}$ 라 두면 기본 비용 정책의 채택 조건은 식 (5)다. $\eta=0.10$ 은 예측 이득을 보수적으로 평가하는 여유율이다.

$$(1 - \eta) \Delta T > \lambda \Delta \bar{w} \quad (5)$$

경로 단계는 시간 합계와 N 배의 최대 시간을 더한 점수로 후보를 평가한다. 폭 단계는 목표 경로 배정에서 식 (4)·(5)를 적용한다. λ 는 정확도 손실을 직접 예측하는 계수가 아니라 폭 보존 비용이며, 설정별 정확도 변화는 III장의 장기 학습으로 검증한다.

다. 참여구성원별 역할

- 성시준: 전체 설계·개발 총괄, 네트워크 제어, KOREN 구성·실험.
- 석태경: 분할 연합학습 파이프라인, 실험 설계·분석, 결과 시각화.

2. 단계별 세부 구현 계획

런타임은 프로파일링, 의사결정 알고리즘, 실행 오케스트레이션의 세 단계로 구성한다. 라운드 경계에서 모델과 경로를 결정하고, 배치 실행 중에는 전송 엔진이 해당 설정을 집행한다. 이 구조는 제어 판단과 텐서 전달의 시간 단위를 분리한다.




그림 2. 라운드 단위 제어 파이프라인과 피드백

가. 적응형 제어 파이프라인

표 3. 제어 단계별 입력과 출력

단계	입력	출력
프로파일링	사전 연산 측정 전송 바이트·활동 시간	연산·전송 프로파일 중계 실효 용량 추정
의사결정	프로파일·현재 배정 허용 경로·용량 상한	다음 라운드의 폭 중계 배정·분할비
실행·피드백	선택한 설정 전역 모델의 파라미터	클라이언트별 모델·연결 라운드 결과·전송 기록

1) 프로파일링과 관측값의 갱신

사전 진단은 전폭의 순전파·역전파 시간 c_i 와 왕복 텐서 바이트 b_i 를 측정한다. 이 연산 프로파일과 폭 지수 γ 를 식 (3)에 적용하며 γ 의 기본값은 1.2다. 선택적 단독 업로드 프로브는 다른 클라이언트를 쉬게 한 뒤 RTT를 뺀 전송 시간으로 접속 상한을 추정한다.

실행 중에는 연결별 바이트와 활동 시간, 당시 중계 배정을 수집한다. 최근 3라운드의 포화 관측 중앙값으로 중계 용량을 추정하고, 관측 전송 시간과 당시 배정의 예측값을 비교해 효율·잔차를 보정한다. 같은 보정값으로 다음 경로 후보를 비교하여 이전 배정의 혼잡을 새 배정에 그대로 적용하는 오류를 줄인다.[12]

2) 경로 우선 탐색과 선택적 폭 축소

의사결정은 식 (4)의 시간·폭 비용을 줄이는 두 단계 휴리스틱으로 구성한다. 먼저 현재 폭을 고정하고 허용 중계 조합을 탐색한다. 경로 단계의 전송 시간은 관측/모형 비율로 보정하고, 폭 단계는 식 (3)의 가산 잔차를 사용한다. 경로 평가는 최대 완료 시간과 전체 클라이언트의 시간 합계를 함께 고려하며, 아래 점수 G 가 낮은 배정을 선택한다. 최대 시간 항에 N 을 곱해 한 스트래글러의 지연을 여러 클라이언트의 작은 이득으로 상쇄하는 선택을 억제한다.

$$G(P | w) = \sum_i \hat{T}_i(w, P) + N \max_i \hat{T}_i(w, P) \quad (6)$$

다음으로 이동 수 제한을 풀어 계산한 목표 배정에서 폭을 평가한다. 최대 지연 클라이언트와 근접한 지연 집단을 함께 한 단계 줄였을 때의 ΔT 를 구하고, 식 (5)의 $(1-\eta)\Delta T > \lambda\Delta w$ 를 만족하는 축소를 채택한다. 이 방식은 현재의 이동 과도기보다 경로 조정 이후의 상태를 기준으로 모델 용량을 결정한다.

탐색 복잡도는 후보 평가 횟수로 관리한다. 중계 K 개를 두 연결에 배정하면 클라이언트별 후보 C 는 최대 K^2 개다. 전체 조합 $Q = \prod_i C_i$ 가 20,000 이하이면 전수 평가하고, 이를 넘으면 전송량 순으로 탐욕 배정하여 $O(NC)$ 회 평가한다. 라운드당 M 개 이동을 고르는 추가 탐색은 $O(MNC)$ 회다. 폭 후보 L 단계의 축소 횟수는 최대 $N(L-1)$ 이며, 각 반복에서 최대 N 개 후보를 검토한다. 각 평가에는 공유 용량 계산 비용이 추가된다.

3) 실행 오케스트레이션과 페루프 피드백

서버는 RSTART 메시지에 라운드 번호, 폭, 모델 가중치, 중계 종점과 연결별 분할 가중치를 담아 클라이언트별로 전달한다. 클라이언트는 선택한 서브모델을 구성하고 지속 연결을 재사용한다. 별도로 검증한 순환 선택 모듈은 라운드마다 채널 위치를 이동하고 전역 파라미터 위치에 맞춰 집계한다. 학습 모듈 교체 시에도 전송 인터페이스는 동일하게 유지한다.

주 제어 실험은 폭 0.5·0.75·1.0과 최대 3개 경로 이동을 사용한다. 폭은 한 단계씩 바꾸고 확대는 두 라운드 연속 확인한다. 중계 용량 추정이 바뀐 라운드에는 폭을 유지해 동시 반응을 억제한다. 분할비는 설정 용량과 공유 배정으로, 경로 이동은 관측 용량으로 판단한다. 배치·라운드 기록은 다음 프로파일 갱신으로 되돌린다.

나. 다중 경로 텐서 전송·재조립 엔진

응용 계층(Layer 7) 전송 엔진은 활성값·기울기를 연속 바이트열로 직렬화하고, 연결별 예상 전송률에 비례해 조각 수를 배분한다. 조각 크기는 전체 바이트를 연결 수의 16배로 나눈 값을 64 KiB~1 MiB로 제한한다. 작은 조각은 배분 오차를 줄이고, 하한은 과도한 프레임링 비용을 억제한다.

하나의 텐서를 나누어 보내고, 원래 위치로 복원




그림 3. 지속 TCP 연결의 텐서 분할·재조립

1) 프레임링과 전송 오버헤드

표 4. 구현된 응용 메시지 프레임

구역	형식·길이	내용
고정 헤더	!BII · 9바이트	kind 1B · meta_len 4B payload_len 4B
메타데이터	JSON · 가변 길이	tid · cid · seq · off ln · total · ex
데이터	payload_len 바이트	직렬화된 텐서의 조각

전송 ID(tid)는 재조립 버퍼를, 조각 번호(seq)는 중복을, 위치(off)와 길이(ln)는 저장 구간을 식별한다. 조각당 응용 헤더 비용은 9바이트와 JSON 길이의 합이다. 연결마다 수신 스레드를 두고 송신 작업을 병렬 실행하며, 소켓 쓰기 잠금으로 조각과 완료 회신의 프레임이 섞이지 않게 한다.

2) 비순서 도착과 동기화 배리어

수신부는 전송 ID별 전체 길이의 버퍼를 할당하고 조각을 지정 위치에 기록한다. 중복·접침·길이 불일치를 검사하며, 완료 신호가 먼저 도착해도 나머지 조각을 기다린다. 전체 길이와 일치하면 완료 회신을 보내고 완성된 텐서를 학습 입력으로 반환한다. 이 수신 완료 배리어가 부분 텐서로 연산하는 오류를 막는다.

3) 전송·학습 모듈 분리와 비동기 완료 확인

송신 측은 전송마다 완료 회신을 동기적으로 기다리는 대신 후속 전송에서 도착한 회신을 검사하고 라운드 종료 시 flush로 모두 확인한다. 서버의 기울기 송신은 별도 작업 스레드가 맡아 세션 처리가 소켓 대기에 묶이는 시간을 줄인다. 연결을 재사용해 반복적인 연결 설정 비용도 줄인다. 송신 버퍼 제한으로 느린 연결에 전송 작업이 과도하게 쌓이는 것을 억제한다.

전송 엔진의 인터페이스는 전송 ID와 바이트열이고, 학습 모듈은 텐서의 형상·자료형과 파라미터 위치를 관리한다. 배치마다 완성된 텐서를 복원하고 라운드마다 모델을 집계하는 경계로 모듈을 분리했다. 현재 직렬화·복원은 연속 버퍼와 명시적 복사를 사용하며, 상위 알고리즘은 연결·제조립 내부를 변경하지 않고 교체할 수 있다.

다. 네트워크 에뮬레이션과 실제 하드웨어 계측

KOREN 테스트베드는 HPC의 클라이언트 프로세스, 실제 VM 2대의 논리 중계 4개, V100 학습 서버로 구성한다. Linux tc의 HTB qdisc로 HPC 송신의 접속 상한과 VM 중계의 공유 용량을 따로 설정한다. VM 수신은 IFB로 넘겨 속도를 제한하고 반환 방향에도 동일한 상한을 적용한다. 지연 주입은 설정 시 netem으로 적용하며, 실제 중계 큐에는 fq_codel을 사용한다.[11,12]

분리한 두 상한은 여러 연결을 열어도 같은 접속 회선을 쓰면 합산 전송률이 무제한 늘지 않는 조건을 재현한다. 로컬 회선 에뮬레이터도 접속과 공유 중계를 두 단계 HTB로 분리한다. KOREN 주 비교에서는 연결별 독립 접속 조건을 사용하므로, 결과 표에 기준 1개·결합 2개 연결을 함께 표시한다.

교란 스크립트는 라운드 로그를 기준으로 같은 조건을 두 정책에 적용한다. 트래픽 몰림은 8라운드에 중계 용량 56→14 Mbps, 20라운드에 56 Mbps로 복구한다. 용량 변동은 7 Mbps 간격의 하강·복구 일정을 적용한다. 조건 원장, 실행 인자, 시드, 교란 로그, 사전 프로파일과 라운드 JSONL을 보존해 설정과 실행 결과를 대조한다.[12,13]

Jetson Orin Nano Super 8GB에서는 전력 모드별 LoRA 스텝 시간과 메모리 비용을 별도 계측했다. KOREN 전송 기록은 경로의 통신 비용을, Jetson 기록은 실제 장치의 연산 비용을 확인하는 자료로 사용한다. 장치·모델·랭크·배치 크기와 표본 수를 III장에 명시했다.

Ⅲ. 아이디어 개발 진행 내용 및 결과

1. 개발 수행 현황 및 최종 결과물

가. 하드웨어 부분

KOREN VM 두 대와 HPC의 CPU·V100 서버를 연결해 실제 텐서를 전송했다. 별도로 Jetson Orin Nano Super 8GB 한 대에서 Qwen2.5-0.5B LoRA의 전력 모드별 연산 특성을 측정했다. 랭크 32, FP32, 배치 1, 시퀀스 길이 256을 고정하고 워밍업 이후 모드별 30스텝을 분석했다.[13]

표 5. Jetson의 전력 모드별 스텝 시간 중앙값

전력 모드	스텝 시간	표본
MAXN SUPER	554.1 ms	30스텝
25 W	608.9 ms	30스텝
15 W	903.7 ms	30스텝

15 W 모드의 중앙값은 MAXN SUPER의 약 1.63배였다. 같은 장비에서도 연산 시간이 달라지므로 스케줄러가 고정 장치 등급 대신 관측한 연산 시간을 사용할 필요가 있다. CPU 기반 Qwen2.5-7B 전체 모델 LoRA는 메모리 부족으로 중단됐고, 별도 분할 실행은 클라이언트 최대 RSS 약 7.94 GB에서 10스텝을 완료했다.

나. 소프트웨어 부분

완성한 모듈은 CNN 서브모델 추출·집계, 연산·통신 관측, 폭·경로 계획, 지속 TCP 전송, 텐서 재조립, 실행 로그와 비교 결과 조회 화면이다. FedRolex식 채널 순환 선택은 별도 300라운드 실행으로 검증했다. 전송 제어와 모델 선택을 분리해 학습 알고리즘의 변경을 수용하도록 구성했다.

LoRA 공동 학습은 KOREN VM 두 대의 논리 클라이언트 세 개와 HPC 서버에서 실행했다. Qwen2.5-0.5B를 두 번째 디코더 계층 뒤에서 분할하고 랭크 16, 16라운드×30스텝으로 학습했다. 자체 18문항에서 미학습 0개, 단독 학습 6개, 두 연합 집계 방식은 각각 12개가 정답이었다.[13]

2. KOREN 연동 및 활용 결과

가. 실경로 관측과 축소 실험

KOREN과 같은 연구망에서도 여러 클라이언트가 같은 시점에 데이터를 보내면 종단 간 전송 구간에 경합이 생긴다. 본 프로젝트는 HPC에서 KOREN VM을 경유하는 실제 텐서 전송을 먼저 측정했다. 접속·중계 상한을 4 Gbps 수준으로 높인 조건에서 동시 전송 수를 8~96개로 늘려, 낮은 인위적 제한에 앞서 실제 경로에서 생기는 지연을 확인했다.[11]




그림 4. KOREN 종단 간 경로의 동시 전송 규모별 완료 시간

배치 왕복 중앙값은 8개에서 0.41초, 32개에서 2.18초로 늘었다. 이 관측은 양호한 연구망에서도 학습 트래픽의 동시성이 완료 지연을 만들 수 있음을 보여준다. 측정 범위는 HPC·접속 구간·VM을 포함한 종단 간 경로이며, 지연의 발생 지점을 KOREN 코어 장비 하나로 특정한 실험은 아니다.

이 병목을 반복 평가하기 위해 SHRiNK의 축소 실험 관점을 참고해 회선 용량과 부하 조건을 조정했다.[9] 충분한 학습 프로세스를 장시간 실행하면 CPU와 메모리 부족이 발생하므로, 32개 논리 클라이언트로 단기 제어 응답을 확인하고 8개로 줄여 장기 학습을 수행했다. 회선에 속도 제한과 변동을 적용해 적은 자원에서도 전송 경합과 복구 과정을 관찰했다.

기록의 대역폭 0.1배 조정과 클라이언트 수 32→8 축소는 각각 회선 조건과 계산 자원의 축소다. 실측에서 확인한 병목을 제어 가능한 조건으로 옮긴 것이며, 두 실행의 절대 시간을 직접 합산하지 않는다. 다음 표에 비교별 규모와 교란 조건을 명시했다.

나. 실험 조건과 라운드 완료 시간

표 6. 제어 응답 및 장기 학습의 실행 조건

항목	단기 제어 평가	장기 학습 평가
공통 모델·배치	ResNet-18 / CIFAR-10 분할 위치 2 / 배치 32	ResNet-18 / CIFAR-10 분할 위치 2
규모·반복	32개 논리 클라이언트 24라운드×3시드	8개 논리 클라이언트 200라운드×2시드
실행 배치	HPC CPU 클라이언트·V100 서버 KOREN VM 2대, 논리 중계 4개	동일 연구망 기반의 축소 실행 학습 품질까지 장기 관찰
교란·설정	정상 / 한 중계 1/4 용량 4개 클라이언트 연산 지연 / 용량 변동	$\lambda=18 \cdot 70 \cdot 280$ 실행별 조건은 E7·E8에 수록

단기 평가: 라운드당 4배치, 접속 상한 5/2 Mbps, 정상 중계 용량 각 56 Mbps, 폭 후보 0.5·0.75·1.0, $\lambda=70$, 라운드당 이동 최대 3개. 장기 평가도 라운드당 4배치를 사용했다.




그림 5. 조건별 평균 라운드 완료 시간

트래픽 몰림에서 109.51초가 62.87초로 줄어 42.6%, 연산 지연에서 79.12초가 47.26초로 줄어 40.3% 단축됐다. 몰림 조건의 평균 폭은 0.998로 대부분 유지했고, 연산 지연에서는 느린 클라이언트 4개의 폭을 0.75로 줄였다. 경로 혼잡과 계산 지연에 서로 다른 조치를 적용한 결과다.[11]

기준선은 단일 연결, 결합 구성은 두 연결을 사용하므로 수치는 전체 구성의 비교다. 응용 전송량 감소는 최대 3.12%로 시간 단축보다 작았다. 따라서 보낸 바이트 수와 함께 경합 및 가장 늦은 클라이언트의 완료 시간을 고려해야 한다. 연결 수를 맞추는 비교는 후속 검증에 포함한다.

3. 멘토 의견에 따른 개선사항

멘토 의견은 개발 목표와 실증 범위를 구체화하는 계기가 됐다. 기존 중간보고서의 7월 12일, 7월 30일, 8월 6일 기록은 클라이언트 참여, 혼잡제어와의 경계, 실제 환경 검증, 관측값의 지속성에 대한 검토를 담고 있다.[12]

표 7. 멘토 의견과 반영 내용

기존 기록의 의견	반영 내용
미선택 클라이언트의 기여를 어떻게 볼 것인가	참여 배제보다 클라이언트의 학습 부담과 완료 시간 조정에 집중
혼잡제어와의 경계가 불분명하다	TCP의 패킷 제어와 라운드 단위 모델·중계 선택을 분리
시뮬레이션만으로는 실증이 부족하다	KOREN 실제 전송과 Jetson 장비 측정을 수행
관측 가치가 지속되는가, LoRA가 초점을 흐린다	상태를 반복 관측하고 CNN 제어 평가와 LoRA 확장 실습을 구분

개발 과정에서는 모델 축소의 정확도 문제를 검토해 채널 순환 선택을 추가했고, 모델 크기를 보존하도록 축소 비용 λ 를 도입했다. 경로 선택에는 관측한 전송량과 활동 시간, 공유 접속 상한을 함께 반영했다. 병목의 원인을 확정적으로 분류하기보다 후보 설정에서 예상되는 완료 시간을 비교하는 방식으로 구현했다.

관리 권한도 구분했다. 클라이언트와 엣지 운영기관이 다른 경우에는 허용된 중계 주소와 포트 안에서 연결을 선택한다. 실제 SDN 집행은 권한을 위임받은 구간에 연결한다. 활성값 교환 자체가 프라이버시 보장을 완성하지 않으므로 인증·암호화·접근통제는 운영 정책과 함께 구성해야 한다.

후속 검증은 연결 수를 동일하게 맞춘 경로 비교, 동일 조건의 고정·순환 채널 비교, 목표 정확도 도달 시간의 순서로 진행한다. LoRA에는 랭크별 연산·전송 프로파일을 별도로 측정해 스케줄링 입력으로 연결한다.

4. 결과물의 통합 및 시험/검증 결과

가. 장기 학습과 품질 검증

폭 조절은 속도를 높이는 수단인 동시에 학습할 모델의 크기를 바꾸는 선택이다. 8클라이언트·200라운드 기록에서는 λ 를 바꾸어 시간과 정확도의 관계를 확인했다. 시간은 초기 4라운드를 제외한 평균, 정확도는 마지막 50라운드의 평가 평균이며 각 값을 두 시드에 대해 평균했다. 평가에는 테스트셋의 앞 2,000개 표본을 사용했다.[11]

표 8. 축소 가중치에 따른 시간과 정확도

설정	라운드 시간	평균 폭	정확도	시간 단축
기준선	19.11초	1.000	65.52%	—
$\lambda=280$	15.15초	1.000	65.22%	20.7%
$\lambda=70$	12.90초	0.977	63.17%	32.5%
$\lambda=18$	8.01초	0.832	53.59%	58.1%

$\lambda=280$ 에서는 폭을 유지하면서 시간이 20.7% 짧았고 정확도 차이는 약 $-0.29\%p$ 였다. λ 를 낮추면 더 적극적으로 모델을 축소해 시간이 줄지만 정확도 손실도 커졌다. 이 결과는 네트워크의 여유를 먼저 활용하고 모델 축소에는 비용을 두는 설계의 필요성을 보여준다. 운영 목표에 맞는 λ 는 시간과 실제 학습 품질을 함께 보고 선택한다.

채널 선택 개선은 별도의 4클라이언트·300라운드×3시드에서 검증했다.[12] 이 실행은 FedRolex식 순환 추출과 집계에 구현 근거다.

표 9. 모델 조절 방식과 제어 평가의 관계

실험 계열	주요 목적	해석 범위
24·200라운드 결합 실행	폭·경로 선택의 시간과 품질	해당 실행의 관측 결과
300라운드 순환 선택	FedRolex식 서브모델 추출·집계	별도 실행에서 구현 검증
LoRA 언어모델 실행	다른 모델에서 분할·연합 실행	모델 모듈 확장의 실습 근거

24라운드 최종 정확도 차이는 정상 $+4.63\%p$, 몰림 $-0.50\%p$, 연산 지연 $-1.20\%p$, 용량 변동 $-2.85\%p$ 였다. 이 비교에는 순환 선택 활성화 기록이 없어, FedRolex의 별도 구현 검증과 구분한다.

나. CNN과 LoRA의 학습·추론 시연

최종 결과물의 활용 흐름은 공개 X-ray 분류와 가상 기업의 업무 문답으로 구성했다. 2026년 9월 29일 RTX 3080 한 대에서 세 논리 클라이언트를 순차 실행하고, 학습 로그·집계 결과·저장 모델의 추론 출력을 보존했다. 이 로컬 시연은 앞의 KOREN 실험과 데이터·학습 조건이 다른 별도 실행이다.[15]

표 10. 최종 시연의 실행 조건과 결과

항목	CNN 영상 분류	LoRA 업무 문답
데이터	PneumoniaMNIST+ 학습 4,708장 / 시험 624장	가상 규정 9개 학습 54문장 / 평가 18문항
모델	ResNet-18 채널 비율 0.5·0.75·1.0	Qwen2.5-0.5B LoRA 랭크 16
실행	20라운드 클라이언트당 12스텝	16라운드 클라이언트당 12스텝
결과	시험 정확도 87.02% 543/624 일치, 오분류 81장	기본 0/18 · 단독 6/18 연합 18/18

CNN은 같은 시험 영상의 학습 전·후 예측을 비교하고 저장 모델을 다시 불러와 624개 예측의 일치를 확인했다. LoRA는 운영·고객지원·보안 규정을 나누어 학습한 뒤 동일한 질문의 답변을 비교했다. 평가는 학습한 규정을 다른 표현으로 묻는 자체 문항이며 일반적인 업무 문답 성능을 대표하지 않는다. 병원 시연 역시 공개 연구용 영상의 분류 예시다.

기록 조회 화면은 클라이언트별 손실, 집계 정확도, 실제 생성 답변과 KOREN 원로그의 경로·폭 변경을 표시한다. 로컬 학습과 과거 KOREN 실측을 화면에서 구분하고, 비교 조건과 자료 출처를 함께 제공한다. 시연 영상은 이 화면의 연속 기록으로 구성한다.

IV. 결 론

1. 개발 최종 결과물

AwareNet은 허용 중계 경로로 줄일 수 있는 지연을 먼저 평가하고, 그 배정에서도 남는 지연의 감소가 폭 축소 비용보다 클 때 모델을 조절하는 스케줄러다. 공유 용량을 반영한 후보 평가와 용량 변화 시 폭 유지 규칙을 결합해, 네트워크의 일시적인 혼잡 때문에 모델이 불필요하게 축소되는 상황을 줄이도록 설계했다.

KOREN 실측에서 동시 전송에 따른 지연을 확인한 뒤 축소 환경에서 제어를 검증했다. 32클라이언트 구성의 평균 라운드 시간은 기준선보다 24.6~42.6% 짧았다. 8클라이언트 장기 평가에서는 폭을 유지한 설정으로 20.7% 단축과 약 -0.29%p의 정확도 차이를 관측했다. CNN의 채널 선택 개선, 실제 Jetson의 자원 측정, LoRA의 분할 공동 학습을 통해 모델 조절 모듈의 적용 범위도 넓었다.

2. 기술 구현에 따른 기대 효과




그림 6. 여러 기관의 전역 모델 공동 개선 활용 예시

병원이나 제조 현장마다 계산 자원과 접속 환경이 다르다. 통신이 혼잡한 기관에는 허용된 여유 경로를 활용하고, 연산 부담이 큰 기관에는 적합한 학습 구성을 배정하면 공동 학습의 대기를 줄일 수 있다. 일시적인 자원 부족 때문에 일부 기관이 계속 작은 모델만 학습하는 상황도 운영 정책으로 점검할 수 있다.

기대 효과는 정해진 시간 안에 더 다양한 기관이 모델 갱신에 참여할 여건을 마련하는 것이다. 이를 통해 각 기관의 데이터가 반영된 전역 모델을 지속적으로 개선하는 네트워크 운용을 지원한다. 병원 적용은 향후 활용 시나리오이며, 현재 실증은 KOREN의 CNN 학습, Jetson·LoRA 실행과 공개 데이터 기반 로컬 시연까지 수행했다.

V. 참고문헌

- [1] H. B. McMahan 외. Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS, 2017.
<https://proceedings.mlr.press/v54/mcmahan17a.html>
- [2] C. Thapa 외. SplitFed: When Federated Learning Meets Split Learning. AAAI, 2022.
<https://arxiv.org/abs/2004.12088>
- [3] S. Horváth 외. FjORD: Fair and Accurate Federated Learning under heterogeneous targets with Ordered Dropout. NeurIPS, 2021.
<https://arxiv.org/abs/2102.13451>
- [4] S. Alam 외. FedRolex: Model-Heterogeneous Federated Learning with Rolling Sub-Model Extraction. NeurIPS, 2022.
<https://arxiv.org/abs/2212.01548>
- [5] Z. Lin 외. AdaptSFL: Adaptive Split Federated Learning in Resource-constrained Edge Networks. arXiv:2403.13101v4. 시간 분석 §V-A.
<https://arxiv.org/abs/2403.13101v4>
- [6] A. Al Asif 외. SuperSFL: Resource-Heterogeneous Federated Split Learning with Weight-Sharing Super-Networks. arXiv:2601.02092v2, 2026.
<https://arxiv.org/abs/2601.02092v2>
- [7] Z. Lin 외. SplitLoRA: A Split Parameter-Efficient Fine-Tuning Framework for Large Language Models. arXiv:2407.00952, 2024.
<https://arxiv.org/abs/2407.00952>
- [8] E. J. Hu 외. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
<https://arxiv.org/abs/2106.09685>

참고문헌 및 실험 원자료

[9] R. Pan 외. SHRiNK: A method for scaleable performance prediction and efficient network simulation. IEEE INFOCOM, 2003.

<https://web.stanford.edu/~balaji/papers/03shrinkaCONF.pdf>

[10] KOREN. 연구망 서비스 및 이용 안내.

<https://koren.kr/>

[11] AwareNet. KOREN line_scale 원로그, scen32 및 r8mix_acc 실행 기록. 지표 정의와 원파일 경로는 report_metrics_revised.json, 공개 색인 E1·E3·E7·E8.

<https://sijoon-sung.github.io/AwareNet/site/evidence.html>

[12] AwareNet. 설계기록_컨트롤러, 정식화_결합_시스템, 방향검토보고서, 설계전환_회의록. FjORD/FedRolex 적용 이력, verify2.log, w25r·w50r 실행 기록. 공개 색인 E9.

<https://sijoon-sung.github.io/AwareNet/site/evidence.html#E9>

[13] AwareNet. Jetson 스텝·전력 모드 기록과 LoRA 학습·메모리·문답 평가.

Jetson 복구 커밋 582b1d4. final_report_evidence_2026-09-26.json과 공개 색인 E2·E4.

<https://sijoon-sung.github.io/AwareNet/site/evidence.html#E2>

[14] OpenStack. Writing Your OS-Ken Application. 공식 문서.

https://docs.openstack.org/os-ken/latest/writing_os_ken_app.html

[15] AwareNet. 공개 X-ray 및 가상 업무 규정의 로컬 학습·추론 기록.

2026.09.29. PneumoniaMNIST+ : Yang 외, MedMNIST v2, CC BY 4.0.

<https://sijoon-sung.github.io/AwareNet/site/demo.html>